

# **INTRODUÇÃO À EXPERIMENTAÇÃO**

**Dilermando Perecin**

**Jaboticabal-SP**

**ago/2013**

## SUMÁRIO

1.	<i>INTRODUÇÃO</i>	3
2.	<i>DISTRIBUIÇÃO E MEDIDAS DE DISPERSÃO</i>	4
2.1.	<i>Distribuição de Probabilidade</i>	5
2.1.1.	<i>Distribuição Binomial</i>	5
2.1.2.	<i>Distribuição de Poisson</i>	8
2.1.3.	<i>Distribuição Normal</i>	9
3.	<i>PRINCÍPIOS DA EXPERIMENTAÇÃO</i>	11
4.	<i>AMOSTRAGEM</i>	17
4.1.	<i>Amostragem aleatória simples com reposição</i>	18
4.2.	<i>Amostragem aleatória simples sem reposição</i>	18
4.3.	<i>Tamanho de Amostra</i>	20
5.	<i>ANÁLISE DE VARIÂNCIA</i>	<u>21</u>
6.	<i>ESTIMAÇÃO E TESTES DE HIPÓTESES</i>	<u>29</u>
	<i>Outros testes – PPCM (procedimentos para comparações múltiplas)</i>	<u>34</u>
7.	<i>DELINEAMENTOS EXPERIMENTAIS</i>	36
7.1.	<i>Delineamento inteiramente casualizado (DIC)</i>	38
7.2.	<i>Delineamento em blocos completos casualizados (DBC)</i>	<u>40</u>
7.3.	<i>Delineamento em quadrado latino (DQL)</i>	<u>43</u>
7.4.	<i>Outros delineamentos</i>	<u>45</u>
7.5.	<i>Delineamentos de tratamentos</i>	<u>50</u>
8.	<i>EXPERIMENTOS FATORIAIS</i>	<u>52</u>
	Interação entre fatores	54
9.	<i>ANÁLISES CONJUNTAS DE EXPERIMENTOS</i>	<u>59</u>
10.	<i>REFERÊNCIAS BÁSICAS</i>	66
11	<i>ANEXOS</i>	68

## 1. INTRODUÇÃO

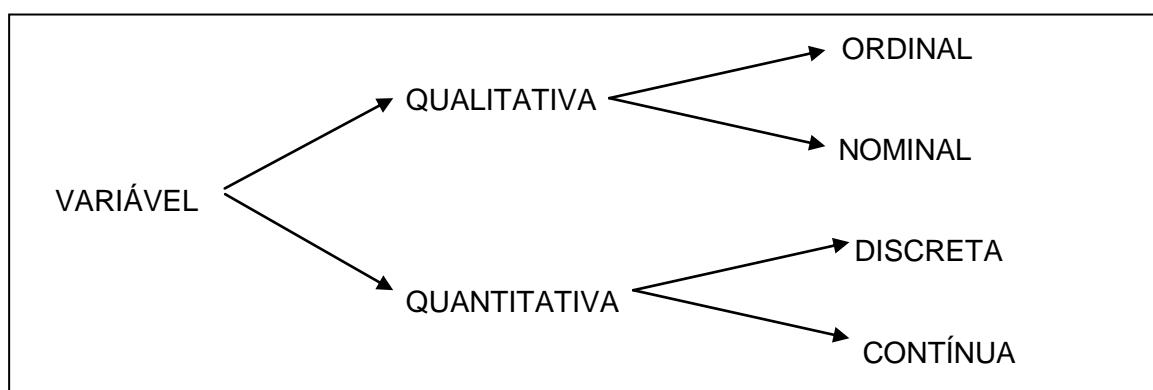
A estatística experimental trata de metodologias para coleta, organização, análise e interpretação de dados obtidos em levantamentos amostrais ou em experimentos especialmente delineados para tal fim, com o objetivo de tomar melhores decisões.

Se as metodologias forem bem empregadas, será possível associar probabilidades às conclusões. Por isso é fundamental que haja um criterioso planejamento e um desenvolvimento cuidadoso de todas as etapas de um experimento, ou levantamento.

Na coleta dos dados as variáveis medidas ou obtidas podem ser qualitativas ou quantitativas. As variáveis qualitativas se apresentam como uma qualidade (atributo) do objeto de estudo. Já as quantitativas se apresentam como valores (números) resultantes de uma contagem ou mensuração.

As variáveis qualitativas podem ser ordinais ou nominais, os valores das variáveis ordinais expressam ordem, por exemplo, a produção de leite de vacas: baixa, média ou alta. Enquanto que os valores das variáveis nominais expressam apenas nomes, sem relacionamento, por exemplo, raça de bovinos de corte (Canchim, Nelore etc..), sexo (macho, fêmea), cor do colmo da cana-de-açúcar (roxo, listrado, verde etc.).

As variáveis quantitativas podem ser classificadas como discretas, por exemplo, número de perfilhos por touceira , número de filhos ou de ovos por ninhada, ou seja, são aquelas cujos valores formam um conjunto finito ou enumerável e normalmente resultam de uma contagem. Ou ainda podem ser classificadas como contínuas, exemplo: peso vivo, altura na cernelha, produtividade leiteira (litros de leite/ha), toneladas de cana por hectare (9tCH) etc., ou seja, valores que normalmente são resultados de mensurações. A Figura abaixo, ilustra os diferentes tipos e classificações das variáveis.



Para cada tipo de variável há uma metodologia estatística mais adequada para a sua organização e análise.

## **2. DISTRIBUIÇÃO E MEDIDAS DE DISPERSÃO**

Geralmente, na prática se utilizam experimentos ou levantamentos cujos, resultados não podem ser previstos com exatidão. Mas, é sempre possível prever um conjunto de possíveis resultados, e existem leis de probabilidade que governam tais resultados.

Na biologia são clássicos os experimentos que Mendel realizou com cruzamento de ervilhas. Os resultados observados se aproximavam dos esperados, mas não eram exatos. Conforme vimos anteriormente, os resultados dos experimentos podem ser qualitativos ou quantitativos. É possível também associar números às variáveis qualitativas, resultando variáveis aleatórias Y com valores observados y, discretos ou contínuos.

O conjunto de todos os possíveis resultados forma a população dos valores. A representação de todos os possíveis valores e probabilidades associadas, na forma de gráfico, tabela ou mesmo por uma função, é chamada genericamente de distribuição dos valores respostas. O conhecimento da distribuição de valores é importante, pois dá uma idéia global da variável em estudo.

Algumas medidas de dispersão importantes para resumir uma distribuição de valores são:

- Variância;
- Desvio padrão;
- Coeficiente de variação.

Para a compreensão de cada uma dessas medidas, tomemos um exemplo de uma distribuição simples com 5 valores.

$$Y=\{1, 2, 3, 5, 9\}$$

- **Média aritmética ( $\mu$ )**

É simplesmente a soma de todos os valores da distribuição, dividido pelo número total deles.

$$\text{Ex: } \mu = (1 + 2 + 3 + 5 + 9) / 5 = 4$$

- **Variância ( $\sigma^2$ )**

É a média da soma dos quadrados dos desvios em relação à própria média. A variância é a medida comumente usada para resumir a variabilidade de uma distribuição, pois mede a concentração dos dados em torno de sua média.

$$\text{Ex: } \sigma^2 = [(1 - 4)^2 + (2 - 4)^2 + (3 - 4)^2 + (5 - 4)^2 + (9 - 4)^2] / 5 = 8$$

- **Desvio padrão ( $\sigma$ )**

Corresponde à raiz quadrada da variância, portanto possui a mesma unidade da média. É considerada uma medida básica de variabilidade, por ser expressa na mesma unidade de valores do conjunto de dados, facilitando a interpretação.

$$\text{Ex: } \sigma = \sqrt{\sigma^2} = 2,83$$

- **Coeficiente de variação (CV)**

É uma medida de variabilidade que deve ser usada quando se compara variabilidades de diferentes conjuntos de dados. O coeficiente de variação é uma medida de variação relativa, a qual expressa o desvio padrão como uma porcentagem da média, ou seja, é o desvio padrão expresso na mesma unidade da  $\mu$  (em %).

$$\text{Ex: } \text{CV} = \frac{\sqrt{\sigma^2}}{\mu} \cdot 100 = 70,71\%$$

## 2.1. Distribuição de Probabilidade

**Definição:** No caso particular de variáveis aleatórias discretas, é uma relação dos distintos valores  $y_i$  de  $Y$ , junto com as suas respectivas probabilidades  $p(y_i)$ , de forma tal que  $\sum p(y_i) = 1$ .

A seguir serão discutidas as distribuições binomial e de Poisson para variáveis discretas e a distribuição normal para variáveis contínuas.

### 2.1.1. Distribuição Binomial

A distribuição binomial associa probabilidade discreta ao número de sucessos numa seqüência de  $n$  experimentos independentes; cada experimento resulta apenas em duas possibilidades, sucesso ou fracasso; e a probabilidade de sucesso,  $p$ , permanece constante.

Para ilustrar, vamos considerar um experimento, onde foram colocadas 4 sementes para germinar (ou gemas para brotar).

Para simplificar, vamos supor que as 4 gemas, sejam de mesma idade e variedade e foram postas para brotar de forma isolada, de modo que uma não possa interagir na

brotação da outra. Suponhamos que o substrato e as condições de umidade também são uniformes..

Como há 4 gemas, cada uma delas poderá brotar ou não. Se a variável medida for  $Y =$  número de gemas brotadas, os possíveis resultados serão: zero (nenhuma brotada), uma, duas ou três sementes brotadas ou ainda quatro (todas brotadas). Dessa forma podemos escrever:  $Y = \{0, 1, 2, 3, 4\}$ .

Qual a chance, em um experimento isolado, de sair qualquer valor particular  $y$  dos possíveis descritos em  $Y$ ?

Essa resposta dependerá das probabilidades  $p$  (suposta constante) de cada gema brotar e do resultado do  $y$  desejado.

Para exemplificar, seja,  $p = \frac{1}{2}$ , então, a probabilidade de cada gema brotar (sb) é  $p = \frac{1}{2}$  (50%) e logicamente a de não brotar (nb) é  $(1 - p) = \frac{1}{2}$  (50%).

Portanto, para  $Y = 0$  temos, (nb), (nb), (nb), (nb) e a probabilidade desse particular resultado é  $P(Y=0) = P(0) = \frac{1}{2} \times \frac{1}{2} \times \frac{1}{2} \times \frac{1}{2} = 1/16$

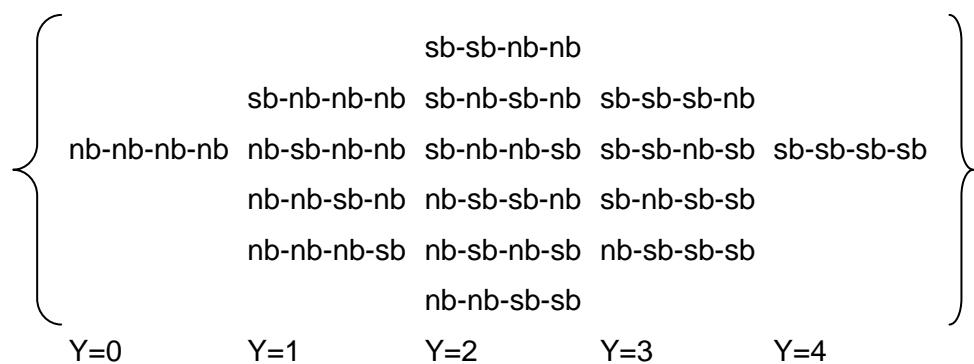
Para  $Y=1$ , qualquer uma das 4 gemas deverá brotar, ou seja, ser (sb) e as outras 3 deverão ser (nb). Há, portanto 4 possibilidades  $P(Y=1)= P(1) = 4 \times 1/16$ , onde 4 é o número de seqüências com 3 sb e uma nb, dada pela  $C_{4,3}$ .

Para  $Y=2$ , quaisquer 2 gemas brotarão (sb) e 2 não brotarão (nb), assim  $P(Y=2) = P(2) = 6 \times 1/16$ .

Para  $Y=3$ , quaisquer 3 gemas brotarão (sb) e uma não brotará (nb),  $P(Y=3) = P(3) = 4 \times 1/16$ .

Para  $Y=4$ , todas as gemas deverão brotar, (gb), ou seja,  $P(Y=4) = P(4) = 1/16$ .

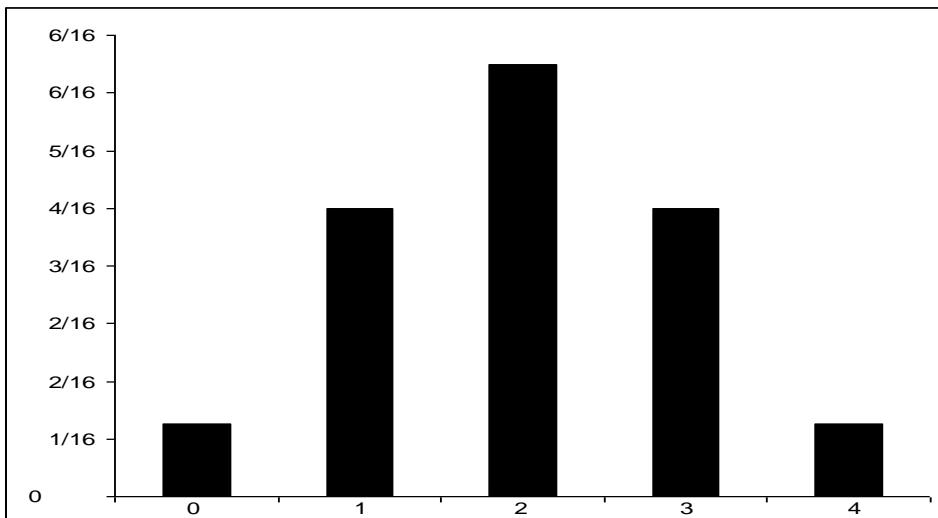
Dessa forma temos ao todo 16 possíveis resultados, que estão ilustrados abaixo:



Podemos então mostrar a distribuição de probabilidades através da Tabela abaixo:

$Y$	0	1	2	3	4
Número de seqüências	$C_{4,0}=1$	$C_{4,1}=4$	$C_{4,2}=6$	$C_{4,3}=4$	$C_{4,4}=1$
$P(Y=y) = p(y)$	$1/16$	$4/16$	$6/16$	$4/16$	$1/16$

Ou gráfico:



Neste caso é possível escrever a função  $p(y) = C_{n,y} p^y (1-p)^{n-y}$ , onde  $y= 0, 1, 2, 3, 4$  e  $C_{n,y}$  é a combinação de  $n$ ,  $y$  a  $y$ ; ou seja,  $C_{n,y} = (n!)/[y! (n-y)!]$ , onde  $n!= 1 \cdot 2 \cdot 3 \dots n$ .

Essa função é conhecida como distribuição binomial. Ela é dependente de “ $n$ ” e de “ $p$ ”, pois é necessário ter  $n$  repetições de um experimento em que  $p$  é constante e o resultado de cada experimento isoladamente não interfere no resultado de outro experimento, ou seja, os experimentos são independentes.

Com a função binomial é possível calcular as probabilidades para qualquer  $y$ , ou seja,  $p(y)$ . Se, por exemplo, forem realizados 1000 experimentos (com brotação de 4 gemas), a freqüência esperada de nenhuma brotar será:

$$f(0) = p(0) \times 1000 = 1/16 \times 1000 = 62,5$$

E assim para as outras probabilidades:

$$f(1) = p(1) \times 1000 = 4/16 \times 1000 = 250$$

$$f(2) = p(2) \times 1000 = 6/16 \times 1000 = 375$$

$$f(3) = p(3) \times 1000 = 4/16 \times 1000 = 250$$

$$f(4) = p(4) \times 1000 = 1/16 \times 1000 = 62,5$$

Dessa forma, a média e a variância esperada de gemas brotadas por lote, tendo a seguinte distribuição de freqüências, será:

y	f(y)
0	62,5
1	250
2	375
3	250
4	62,5
Total	1000

Média esperada:

$$\mu = [\sum y f(y)]/\sum f(y) = 2 \text{ gemas em um lote de 4}$$

Variância esperada:

$$\sigma^2 = \{\sum y^2 f(y)\} - [(\sum y f(y))^2 / \sum f(y)] / \sum f(y) = 1 \text{ de 4 gemas.}$$

Considerando por exemplo 1000 experimentos, com 4 gemas por lote, a freqüência esperada média é que  $2000 = (2 \times 1000)$  gemas brotadas.

### 2.1.2. Distribuição de Poisson

Esta distribuição também se aplica para o caso de elementos ou indivíduos que manifestam de forma independente um efeito (entre duas possibilidades) e com probabilidade  $p$ , tal como na binomial. Só que em vez de  $n$  ser fixo (como na binomial) ele é variável, mas a média ( $\mu$ ) é fixa (constante). Nesse caso, as variáveis aleatórias no geral podem representar o número de ocorrências do evento de interesse em um intervalo de tempo ou em um espaço (superfície ou volume).

A distribuição pode ser usada para calcular probabilidades, por exemplo, quando se semeiam sementes pequenas de difícil individualização, como é o caso da cana-de-açúcar ou de algumas hortaliças. Pode-se distribuir as sementes com uma medida que em média, solta por exemplo 5 sementes por linha ou por área ( $\text{cm}^2$ , por exemplo). Qual a probabilidade de ter 4 sementes em uma linha, após a semeadura?

É possível demonstrar para esse caso, que as probabilidades podem ser estudadas pela distribuição de Poisson:

$$P(y) = (e^{-\mu} \mu^y)/y! , \text{ onde } y= 0, 1, 2, 3\dots ; e = \text{aproximadamente } 2,718\dots$$

Portanto para o exemplo acima, a probabilidade de se ter 4 sementes em uma linha é:  $P(4) = (e^{-5} 5^4)/4! = 0,175$

Da mesma forma podemos calcular a probabilidade de ter 3 ou menos sementes ou ainda 6 ou mais sementes. Exemplos:

$$\text{Para 3 sementes} = P(3) = (e^{-5} 5^3)/3! = 0,140$$

$$\text{Para 6 sementes} = P(6) = (e^{-5} 5^6)/6! = 0,146$$

E assim por diante.

Demonstra-se que para esse caso a média e variância esperadas são iguais (possuem mesmo valor). A distribuição de Poisson se aplica também, com mais simplicidade no cálculo, com aproximação da binomial, quando  $n$  é grande e  $p$  pequeno.

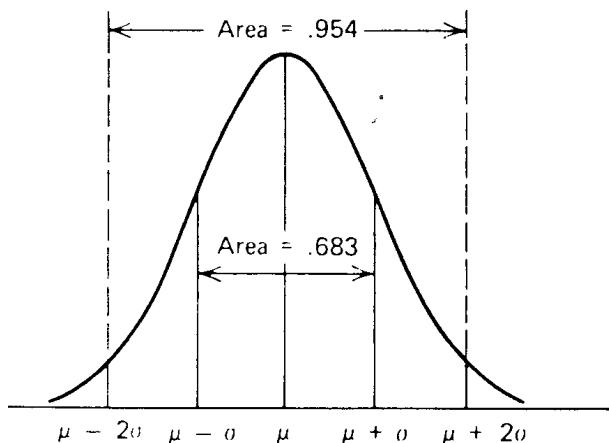
### 2.1.3. Distribuição Normal

A **distribuição normal** é uma das mais importantes, conhecida também como Distribuição de Gauss ou Gaussiana. Além de descrever uma série de fenômenos físicos e financeiros, possui grande uso na experimentação. É inteiramente descrita por dois parâmetros, média e desvio padrão, ou seja, conhecendo-se estes parâmetros consegue-se determinar qualquer probabilidade em uma Normal.

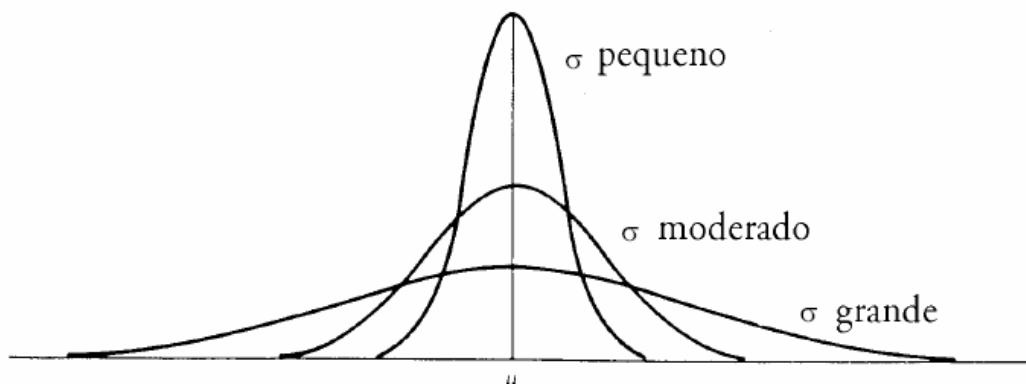
No geral a distribuição normal representa bem as respostas, quando estas são influenciadas por muitos fatores. Por exemplo, altura ou peso de animais de produção são variáveis influenciadas por diversos fatores: genéticos (diferentes genes), climáticos, nutricional, manejo, etc. Assim, os diferentes produções de animais ou de uma culturas (supondo mesmo local e mesma raça etc) geralmente se distribuem segundo uma distribuição normal.

A maior parte dos valores estarão próximos da média geral, mas eventualmente há elementos bem maiores ou bem menores que a média.

Como já informado a distribuição normal pode ser descrita totalmente pela média e pelo desvio padrão. Demonstra-se que 68% dos valores são esperados no intervalo  $\text{média} \pm 1$  desvio padrão. Para incluir 95% dos valores no intervalo, são necessários a média  $\pm 2$  desvios padrões.



O gráfico da função é uma curva na forma de sino, simétrica centrada na média e com desvios padrão determinando a altura e a forma.



A probabilidade entre dois valores  $y_1$  e  $y_2$  é a área sob a curva entre esses dois pontos, podendo ser determinada com o auxílio da tabela normal padrão que disponibiliza essas probabilidades. Usa-se a padronização da variável  $Y$  em uma variável  $Z$  (variável normal padronizada), assim:

$$Z = \frac{Y - \mu}{\sigma}, \text{ onde, } Y: N(\mu, \sigma^2) \text{ e } Z: N(0, 1), \text{ ou seja, } Z \text{ tem distribuição normal com}$$

média 0 e variância 1. Há tabelas com cálculos das probabilidades usando  $Z$ , ver exemplo a seguir.

**Exemplo:** Sabendo-se que o peso de 1.000 bezerros da raça Nelore são distribuídos normalmente, com média ( $\mu$ ) 210 kg e desvio padrão ( $\sigma$ ) 15 kg, (a) qual é o número esperado de bezerros com peso superior a 195 kg?; e (b) que peso deve atingir um bezerro para que ele supere 80% do peso dos bezerros dessa raça?

**Solução:**

$$(a) P(Y > 195) = P\left(\frac{Y - \mu}{\sigma} > \frac{195 - 210}{15}\right) = P(Z > -1)$$

$$P(Z > -1) = P(-1 < Z \leq 0) + P(Z > 0) = 0,3413 + 0,5 = 0,8413$$

Portanto, o número esperado de bezerros com peso superior a 195 kg é  $(1.000 \times 0,8413) \cong 841$  bezerros.

$$(b) P(210 < Y < x) = 0,30$$

$$P\left(0 < Z < \frac{y - 210}{15}\right) = 0,30$$

$$z_c = \frac{y - 210}{15} = 0,84 \quad \Rightarrow \quad y = 222,6 \text{ kg é peso que um bezerro deve atingir para que ele supere 80% do peso médio dos bezerros dessa raça.}$$

### 3. PRINCÍPIOS DA EXPERIMENTAÇÃO

A experimentação pode ser definida como uma parte da estatística que estuda o planejamento, a execução, a coleta de dados, a análise e a interpretação dos resultados dos experimentos. A experimentação é uma forma usual de gerar os valores amostrais em condições controladas, com os quais serão avaliados a cultura, a tecnologia usada, a variedade, a raça, etc. Esse estudo é importante para todo profissional pesquisador e/ou usuário dos resultados da pesquisa.

A agropecuária depende muito da pesquisa experimental, pois, em muitos casos, é só com experimentos, nas condições locais, que se conseguem informações básicas necessárias: qual o melhor dieta; qual a melhor manejo; qual o efeito no campo de certo balanço de nutrientes, e assim por diante.

Cada experimento visa obter amostras, do que seria a resposta naquela condição, com respectiva raça, categoria e manejo. Portanto são amostras de possíveis valores de uma dada população, daí a necessidade de análises estatísticas que associarão probabilidades às decisões que serão tomadas. Por isso, cuidados para que a amostra seja representativa são imprescindíveis. Só assim, as inferências a partir dela poderão expressar uma extração para a população (cultura de um modo geral).

Além disso, para a obtenção de inferências precisas, o pesquisador necessita planejar cuidadosamente o experimento e durante a condução utilizar técnicas refinadas, com o objetivo de minimizar as variações causadas por fatores não controláveis.

Fazem parte do planejamento do experimento: estabelecer os objetivos e hipóteses, relacionar os tratamentos (de acordo com os objetivos propostos), confeccionar o croqui experimental, escolher as variáveis a serem observadas, observar as condições gerais do experimento, planejar a análise dos resultados e elaborar o cronograma de atividades.

Relacionados às diferentes etapas da experimentação, existem alguns conceitos básicos, que são de fundamental importância ao pesquisador ou experimentador ter conhecimento.

**Experimento ou Ensaio:** É constituído basicamente por um conjunto de unidades experimentais sobre as quais são aplicados os tratamentos e colhidos os resultados.

**Tratamento:** É uma entidade qualquer de interesse do pesquisador, pode ser o método, ou o material cujo efeito se deseja medir ou comparar. É a variável que expressa o problema a ser resolvido. Os tratamentos são denominados qualitativos quando se diferenciam por suas qualidades (formas, marcas, métodos, tipos, espécies, variedades, etc.), e quantitativos, quando podem ser ordenados segundo algum critério numérico como,

por exemplo, doses de fertilizantes (0, 10, 20 kg/hectare), doses de “remédios”, espaçamentos entre plantas, quantidade de animais por unidade de área, idade ou tempo.

**Hipóteses e Objetivos:** Todo experimento deve ter como objetivo gerar dados para comprovar ou não alguma hipótese em consideração (ou conjectura). Os objetivos devem ser totalmente pré-estabelecidos e claros. A hipótese pode ser sobre o comportamento de alguma tecnologia, manejo, raça, etc.

**Unidade Experimental ou Parcela:** É a menor unidade de um experimento na qual é aplicado um tratamento. Deve ter tamanho suficiente para reproduzir manejo similar ao empregado na prática e captar as variabilidades existentes. A parcela pode ser uma área de campo, um animal, um curral, uma placa de Petri, um tubo de ensaio, uma planta, ou grupo de animais, uma máquina, etc.

De maneira geral, em experimentos de campo com culturas agronômicas é usual parcelas retangulares com a maior dimensão no sentido da linha. No geral é conveniente que a parcela possua bordadura para evitar efeitos de borda como luminosidade, efeitos de parcelas vizinhas, entre outras.

Com culturas de cereais no campo, as parcelas são formadas de modo a resultar CV (coeficiente de variação) ao redor de 5%; com cana-de-açúcar há maiores problemas com a brotação das gemas e com o perfilhamento e CV ao redor de 10% são muito bons.

Com animais (adaptado de Kalil,1974), os seguintes tamanhos de parcelas e os seus respectivos CV (coeficiente de variação) são usuais.

- 1) Pintos
  - 1.1) Observam-se no geral peso/ave e conversão alimentar.
  - 1.2) Com 8 a 10 aves/parcela, espera-se CV para peso corporal ao redor de 10%.
  - 1.3) Com 50 a 60 aves, espera-se CV para peso corporal ao redor de 1,5%, ideal para experimentos mais sensíveis.
- 2) Poedeiras: postura
  - 2.1) Parcelas no geral com 4 a 8 aves.
  - 2.2) É aconselhável um a dois meses de controle prévio da postura para separar grupos uniformes.
  - 2.3) CV esperado para postura (nº ovos/ano/ave), ao redor de 2,5%.
- 3) Ovinos: ganho de peso
  - 3.1) Parcela com 1 ou mais animais , dependendo da disponibilidade e das instalações.
  - 3.2) Inicia-se pesando com 14 dias e acompanha semanalmente até 12 semanas.

- 3.3) Ganho de peso ao redor de 10 kg, dependendo de raça e do tratamento, e CV menor que 10%.
- 4) Suínos: ganho de peso
- 4.1) Parcela com um leitão ou toda leitegada.
  - 4.2) Pesos até a desmama, mais ou menos aos 56 dias, ou após isso a cada 14 dias.
  - 4.3) Peso esperado aos 250 dias ao redor de 100 kg, dependendo da raça e do tratamento, e CV até menor que 5% é bom.
- 5) Bovinos de corte: ganho de peso
- 5.1) Parcelas com um só animal (preferível), exceto para os casos de pastejo ou de baias coletivas.
  - 5.2) É aconselhável período experimental preliminar, quando os animais são acostumados a rotina de pesagens etc.
  - 5.3) Pesa-se, no geral, a cada 28 dias, preferencialmente de manhã, suspendendo-se água e tratamentos na tarde do dia anterior.
  - 5.4) Ganho de peso diário varia no geral de 0,5 a 1,5 kg diários, dependendo da raça e do tratamento, e CV até menor que 5% é bom.
- 6) Vacas leiteiras
- 6.1) A curva de lactação aumenta após a parição, atinge o pico e depois decresce lentamente.
  - 6.2) Parcela de uma vaca, exceto nos casos de pastejo, que se usam 2 ou 3.
  - 6.3) Exige período preliminar de preparação para que as vacas acostumem com a rotina experimental.
  - 6.4) Há necessidade de padronização do período de lactação:
    - Para 10 semanas o CV esperado é de 4 a 8%.
    - Para 20 semanas o CV esperado é de 7 a 11%.
    - Para 30 semanas o CV esperado é de 10 a 15%.

**Controles ou Testemunhas:** Na maior parte dos experimentos, o objetivo é avaliar uma técnica ou dieta ou manejos etc., que recebem a denominação genérica de tratamentos. Os quais são avaliados em relação a um ou mais tratamentos controles ou testemunhas que normalmente são técnicas ou padrões reconhecidos, e por isso servem como comparativo. De modo que no planejamento do experimento a inclusão de adequados controles é fundamental para a interpretação dos resultados.

**Delineamento Experimental:** É o plano utilizado na experimentação e implica na forma como os tratamentos serão designados ou arranjados nas unidades experimentais. É feito no sentido de evitar influências de fatores estranhos e propiciar condições para que os tratamentos possam expressar seus verdadeiros efeitos.

O delineamento será escolhido em função da disponibilidade de parcelas homogêneas, de material para sua instalação, condução e colheita. Portanto, há necessidade de conhecimento do local, do animal e da condução do próprio experimento para que o planejamento do delineamento seja adequado.

Como exemplos de delineamentos experimentais, podem ser citados: delineamento inteiramente casualizado, delineamento em blocos casualizados, delineamento em quadrado latino e outros. Alguns serão vistos no item 5 desta apostila e consultas adicionais podem ser vistas nas referências bibliográficas, item 8.

**Bloco:** É um dos conceitos fundamentais na experimentação. Trata-se de um conceito teórico, nem sempre fácil de usá-lo adequadamente na prática. Conceitualmente, são subconjuntos de parcelas homogêneas, nas quais as respostas relativas dos tratamentos se manifestam de forma independentemente do bloco.

Jamais o conceito de bloco pode ser confundido com repetição, embora seja usual o delineamento apresentar uma repetição de cada tratamento por bloco.

**Modelo de análise:** Muito frequentemente os resultados de um experimento podem ser analisados por mais de um modelo.

Por exemplo, em um experimento em que os tratamentos são representados por doses de um produto; podemos supor um modelo em que há uma média em cada tratamento ou um modelo em que há uma curva passando por essas médias. Evidentemente, se a curva for verdadeira é melhor, pois a interpolação entre as doses, escolha de dose ótima etc., poderão ser feitas com mais propriedade. Por outro lado, há casos em que a curva é completamente desconhecida e o modelo com uma média por dose produz uma análise mais satisfatória.

**Balanceamento e ortogonalidade:** Balanceamento e ortogonalidade são outros dois princípios importantes, embora não essenciais. Na experimentação é desejável que todos os tratamentos sejam comparados com igual precisão, uma das condições para isso é que todos os tratamentos tenham iguais números de repetições (balanceamento).

O conceito de ortogonalidade ou de independência dos efeitos estimados também é desejável. No geral, o balanceamento é uma das condições para ortogonalidade.

A pesquisa científica está constantemente se utilizando de experimentos para provar suas hipóteses. É claro que os experimentos variam de uma pesquisa para outra, porém, todos eles são regidos por alguns princípios básicos, necessários para que as conclusões que venham a ser obtidas se tornem válidas. Esses princípios básicos foram estabelecidos

por Fisher e envolvem a existência de REPETIÇÃO de unidades experimentais, CASUALIZAÇÃO destas unidades e CONTROLE LOCAL (controle de fator extra interferente, uniformidade)

O princípio da repetição refere-se à aplicação do mesmo tratamento sobre duas ou mais unidades experimentais, e o princípio da casualização é a alocação dos tratamentos aleatoriamente sobre as unidades experimentais, isto é, sorteando qual a unidade experimental receberá cada tratamento e cada repetição. A maneira de se proceder a casualização resulta no terceiro princípio, denominado controle local ou restrição à casualização.

As repetições são necessárias para estimar o *erro experimental* e para avaliar, de forma mais precisa, o efeito de cada tratamento, ou seja, para estimar a variabilidade e conferir precisão ao valor estimado. Erro experimental é a variância entre os valores observados nas unidades experimentais que receberam o mesmo tratamento.

Sabe-se que no geral é mais eficiente aumentar o número de repetições e diminuir o tamanho da parcela, do que o contrário. Um balanço entre o que é estatisticamente desejável e o que é economicamente viável irão decidir qual será o número de repetições e qual será o tamanho adequado da parcela.

No entanto, sabe-se que para detectar grandes diferenças bastam poucas repetições e para pequenas diferenças há necessidade de grande número de repetições. De um modo geral, na experimentação, é usual que os experimentos possuam pelo menos 20 parcelas e que a variabilidade seja estimada no mínimo com 10 graus de liberdade (esse conceito será discutido adiante).

A casualização é usada para obter a independência dos erros, que é uma exigência desejável nos modelos matemáticos usados pela estatística na interpretação dos resultados obtidos nos experimentos, e deve ser satisfeita para se fazer certas inferências estatísticas sobre o comportamento dos tratamentos com base nos dados obtidos. A casualização no geral leva à obtenção de estimativas imparciais das médias dos tratamentos e a independência do erro experimental.

O esquema a seguir ilustra o princípio da casualização, em um croqui de um experimento fictício com 4 tratamentos (A, B, C, D) e cinco repetições (1, 2, 3, 4, 5). Em princípio, é suposto que todas parcelas, antes da aplicação dos tratamentos, são todas homogêneas; o que é típico do delineamento inteiramente casusalizado (DIC), discutido no item 6 desta apostila.

1 B	5 D	3 A	4 B	5 A
4 C	5 C	1 D	2 A	3 D
1 A	2 D	3 C	2 B	4 D
2 C	3 B	4 A	1 C	5 B

Por outro lado, o controle local ou de fatores interferentes modifica a forma como os tratamentos estão casualizados nos experimentos. Dele se formam os diversos delineamentos experimentais (item 7). O delineamento inteiramente casualizado, no qual se supõe a homogeneidade das condições experimentais, a casualização é realizada sem a realização do controle local. Porém como a maioria dos experimentos, principalmente os de campo, pode ser realizada em condições não totalmente homogêneas e a área experimental deverá ser separada em blocos e os tratamentos devem ser casualizados dentro de cada bloco, a fim de se obter um controle e não favorecer um ou outro tratamento. O delineamento experimental mais freqüentemente utilizado é o de blocos com tratamentos casualizados. Isso será abordado detalhadamente no item 6 desta apostila.

#### 4. AMOSTRAGEM

Na realização de qualquer estudo quase nunca é possível examinar todos os elementos da população de interesse, seja por questões de tempo, economia ou da forma de análise. Por exemplo, se o interesse é examinar a qualidade de ovos antes de irem ao supermercado, não podemos analisar todos os ovos, por questão de viabilidade e de preservação do produto.

Assim, a solução é selecionar parte dos elementos (amostra de ovos), analisá-la e inferir propriedades para o todo (população de ovos).

**População** é o conjunto de indivíduos (objetos), tendo pelo menos uma variável comum observável, ou seja, é constituída por todos os valores possíveis com a distribuição conhecida ou não.

Como na prática é muito difícil ou até mesmo impossível trabalhar com todos os valores, normalmente trabalhamos com amostras.

**Amostra** é qualquer subconjunto da população.

Felizmente, podemos analisar uma amostra, pois há leis que governam as relações entre os valores amostrais e os valores da população da qual a amostra foi extraída, desde que a amostragem seja bem feita.

A maneira de se obter a amostra é tão importante, e existem tantos modos de fazê-lo, que estes procedimentos constituem uma especialidade dentro da Estatística, conhecida como **Amostragem**.

No momento em que decidimos obter informações por meio de um levantamento amostral, temos de imediato definir a população de interesse e selecionar a característica que iremos estudar. A população-alvo é a população sobre a qual iremos fazer inferências baseadas na amostra.

Para que possamos fazer inferências válidas sobre uma população a partir de uma única amostra dela extraída, é preciso que esta seja representativa da população. Uma das formas de se conseguir representatividade é fazer com que o processo de escolha da amostra seja de alguma forma aleatório, isto é, de modo casual. Além disso, a aleatoriedade permite o cálculo de estimativas dos erros envolvidos no processo de inferência.

As medidas (por exemplo, média, variância, desvio padrão, etc.) obtidas com todos os valores da população ou distribuição são chamadas parâmetros, enquanto que as correspondentes obtidas com amostras são chamadas ESTATÍSTICAS.

Portanto as estatísticas variam de amostra para amostra e é por isso que é fundamental que a amostragem seja bem feita para representar a população. Em uma mesma amostra podem ser obtidas mais de uma estatística, sendo que, as melhores são as

não viciadas e que apresentam erro padrão mínimo. Erro padrão é o desvio padrão de uma estatística.

Descreveremos a seguir os métodos mais comuns de extração de amostras probabilísticas. Ao descrevê-los, estaremos sempre tratando de obter uma amostra de tamanho  $n$  em uma população de tamanho  $N$ .

#### **4.1. Amostragem aleatória simples com reposição**

Os elementos da amostra ( $n$ ) são selecionados um de cada vez, a partir dos elementos da população ( $N$ ), repondo o elemento sorteado na população antes do próximo sorteio. Com tal procedimento, qualquer elemento pode ser sorteado mais do que uma vez. As  $n$  seleções são independentes e cada elemento na população tem a mesma probabilidade de inclusão na amostra. Amostra aleatória com reposição é caracterizada pela propriedade que cada possível seqüência de  $n$  unidades, distinguindo ordem de seleção e possibilidade de inclusão de seleções repetidas, tem igual probabilidade sob o delineamento amostral.

Com esse tipo de amostra é possível deduzir algumas propriedades interessantes.

Se tomarmos amostras aleatórias de tamanho  $n$ , de uma população de tamanho  $N$ , com média “ $\mu$ ” e variância “ $\sigma^2$ ”. Então, cada amostra “ $i$ ” terá uma média  $\bar{x}_i$  e uma variância  $s_i^2$ , onde,  $\bar{x}_i = \sum x_i/n$  e  $s_i^2 = \{\sum x^2 - [(\sum x)^2/n]\}/(n-1)$ .

Diferentemente da variância da população ( $\sigma^2$ ) em que o denominador é  $N$  na variância amostral ( $s^2$ ), o denominador é  $(n-1)$ , pois, para a amostra é necessário fazer uma correção para garantir a propriedade de não vício.

Demonstra-se que a média de todas as médias possíveis ( $\bar{x}_i$ ), será  $\mu$  (média da população), ou seja, não haverá vício. A variância das médias  $\bar{x}_i$  será  $\sigma^2/n$ , ou seja, tanto mais confiáveis são as inferências, quanto maior for o tamanho da amostra, o que já faz parte do senso usual.

Uma vantagem prática deste tipo de amostragem é que, em algumas situações, é uma conveniência importante não ser necessário averiguar se qualquer elemento nos dados está incluído na amostra mais de uma vez.

#### **4.2. Amostragem aleatória simples sem reposição**

A amostra pode ser obtida por  $n$  seleções em que, em cada passo (seleção), todos os elementos não selecionados da população, têm igual chance de seleção.

Equivalentemente, pode-se tomar uma seqüência de seleções independentes da população total, tendo cada elemento, em cada passo, igual probabilidade de seleção, descartando seleções repetidas e continuando até que n elementos distintos sejam obtidos.

Se a amostra for sem reposição e a população for finita ( $N$  pequeno), a variância das médias deve ser corrigida pelo fator  $(N-n)/(N-1)$ , ou seja,  $\sigma^2 = (\sigma^2/n) \cdot [(N-n)/(N-1)]$ .

Se a população for grande, não há necessidade do fator de correção, nem que a amostra seja sem reposição (o que é o mais usual).

Como  $\sigma^2/n$  é uma dispersão das possíveis  $\bar{x}_i$ , pode-se calcular o tamanho da amostra  $n$ , prefixando o valor da dispersão.

Por exemplo, se ao longo do tempo, amostras de 40 metros lineares de uma variedade de cana-de-açúcar mostraram  $\mu = 100$  t/ha e  $\sigma^2 = 100$  t<sup>2</sup>/ha, quantas amostras devemos tomar, para que a variância das medidas dessas amostras seja 10 t<sup>2</sup>/ha?

Solução: Sabemos que: variância das médias  $\bar{x}_i$  será  $\sigma^2/n$ , então:

$10$  t<sup>2</sup>/ha =  $\sigma^2/n$ , portanto  $n=10$ , ou seja, 10 amostras de 40 m serão suficientes para dar a dispersão desejada.

Há outros tipos de amostras probabilísticas: estratificada, conglomerado, hierárquica, sistemática, entre outras, que podem ser vistas em textos específicos, citados nas referências bibliográficas, item 8.

#### 4.3. Tamanho da amostra

Há vários critérios para definir o tamanho da amostra. Alguns exemplos

##### Critério do Coeficiente de Variação.

Uma possibilidade é compor amostras individuais independentes, para formar uma amostra composta de tamanho  $n$ . Procedimento:

- Encontrar o CVi com amostras individuais (no geral mais de 50).
- Tomando  $n$  amostras ao acaso, o CVn da média é  $CV_n = CV_i/n^{1/2}$ .

$$n = (CV_i / CV_n)^2$$

Exemplo, vamos supor que com 100 amostras, CVi = 50%

Qual o tamanho da amostra para que CVn=12,5%

Solução:

$$n = (50/12,5)^2 \quad \text{Ou seja, } n = 16.$$

Outra possibilidade é compor amostras com áreas adjacentes, não independentes, para formar uma amostra com tamanho suficiente para captar a variabilidade existente. Plotando-se o CV em função do tamanho da amostra, pode-se escolher o tamanho para um CV desejado.

### **Critério da média mínima (usual três).**

Esse critério pode ser usado com pragas ou com atributos que apresentam incidência baixa. Será preciso ter um tamanho da amostra suficiente, para alguma representatividade. Baseia-se na distribuição da incidência, sem reboleiras muito marcantes, ou seja, com uma distribuição aleatória. O esperado é a distribuição de Poisson.

Pela Poisson a  $p(0) =$  probabilidade de não encontrar  $= e^{-m}$  ( $m=$ média).

Para  $m=3$ ,  $1 - p(0) = 0,95$  (ou seja, nesse tamanho de amostra há 95% de confiança de encontrar indivíduo com a incidência estudada).

Portanto:

Para incidência de 1%, temos que ter amostra mínima de 300.

Se a incidência for de 2%, temos que ter amostra mínima de 150

Se a incidência for de 3%, temos que ter amostra mínima de 100

Se a incidência for de 5%, temos que ter amostra mínima de 60.

Etc

### **Critério do erro padrão**

Erro padrão é o desvio padrão de uma estatística. No caso da média, esse valor é denominado epm e pode ser estimado no caso de amostras aleatórias por  $s/n^{1/2}$ .

Fixando-se um valor E para o epm, obtém-se:  $n = (s/E)^2$ .

Para o caso de porcentagens binomiais, usa-se o máximo esperado para erro padrão da proporção  $(p(1-p)/n)^{1/2} = (0,25/n)^{1/2}$  e obtém-se:  $n = 0,25/E^2$ .

No caso de pesquisas eleitorais, é usual tomar  $E = 0,02$  (2%), obtendo  $n=625$  pessoas.

Esse critério também se aplica de forma similar, substituindo o erro padrão pelo erro da estimativa, tratado no item 6.

## 5. ANÁLISE DE VARIÂNCIA

A análise de variância, também conhecida como ANOVA (Analysis of variance), é uma técnica que consiste, fundamentalmente, em decompor a variância total de um conjunto, em variâncias parciais, correspondentes a fontes de variação diferentes e determinadas. Feito isto, as variâncias poderão ser comparadas entre si por meio de algum teste estatístico.

Podemos fazer uma análise de variância com dados que tenham distribuição conhecida ou não. A partir daí para a realização de testes de hipóteses estatísticos é necessário que o conjunto de dados obedeça algumas pressuposições, mas isso será discutido no item 6 desta apostila.

Para facilitar o entendimento da ANOVA, tomemos um caso simples em que há apenas um fator de tratamento e esse tratamento seja qualitativo.

Se denotarmos as respostas como “y”, a soma de quadrados dos desvios em relação à média é simplesmente denotada como soma de quadrados total:

$$SQ_{\text{Total}} = \sum_{j=1}^c (y_j - \bar{y})^2$$

Se entre os y tiverem “t” tratamentos, podemos identificar os tratamentos, supondo todas as parcelas homogêneas (como no caso do DIC, item 7), por  $i = 1, 2, \dots, t$ , e as médias desses tratamentos por  $\bar{y}_i$ , sendo cada média proveniente de  $r_i$  valores e  $\sum r_i = N$

Algebraicamente, mostra-se que:

$$SQ_{\text{Total}} = \sum_i (\bar{y}_i - \bar{y})^2 + \sum_i \sum_j (y_{ij} - \bar{y}_i)^2, \text{ ou seja, } SQ_{\text{Total}} = SQ_{\text{Tratamentos}} + SQ_{\text{Resíduo}}$$

Uma outra maneira equivalente de se chegar a essa partição é supondo o modelo:

$$\text{Resposta (y)} = (\text{média de tratamentos}) + \text{resíduo}$$

O resíduo, no caso, é também denominado “erro puro” expressando a variabilidade ao redor da média de cada tratamento (que é estimada, na prática, pela média amostral de cada tratamento).

Demonstra-se que associados a  $SQ_{\text{Total}}$  existem  $(n-1)$  graus de liberdade, para a  $SQ_{\text{Tratamentos}}$  há  $(t-1)$  graus de liberdade e para a  $SQ_{\text{Resíduo}}$  tem-se associados  $(n-t)$  graus de liberdade.

O grau de liberdade é um parâmetro associado a cada estatística ou fonte de variação (soma de quadrados) e expressa o número de valores independentes que ela contém. No caso da ANOVA, com uma média por tratamento ou grupo os graus de liberdades associadas a essa fonte de variação será igual ao número de tratamentos -1, os

graus de liberdade total será  $n-1$ , e os graus de liberdade do resíduo será a diferença entre os dois.

Fontes de variação (FV)	Graus de liberdade (GL)
TRATAMENTOS	Trat -1
RESÍDUO	$GL_{total} - GL_{trat}$
TOTAL	$(trat*rep) - 1$

Para a melhor compreensão do conceito de grau de liberdade usaremos um exemplo mais simples.

Seja uma amostra de 4 valores ( $y_1, y_2, y_3, y_4$ ) com média ( $\bar{y}$ ) igual a 5. Quantos valores podem ser “chutados” independentemente lembrando que existe a restrição que  $\bar{y} = 5$ ?

Resposta: 3 valores. Por exemplo, ( $y_1=2; y_2=7; y_3=7$ ), pois o  $y_4$  tem que ser obrigatoriamente igual a 4 para que  $\sum y_i = 20$  e a  $\bar{y} = 5$ , respeitando assim a restrição.

Outros valores poderiam ser:  $y_1=6; y_2=3; y_3=2$ , dessa maneira  $y_4 = 9$ , portanto para este exemplo temos 3 graus de liberdade. Pois, é possível “chutar” 3 dos 4 valores independentemente.

Voltando à questão da partição da soma de quadrados total ( $SQ_{Total}$ ). Quando essa for partida em duas, como no caso do exemplo inicial, podemos representar os valores de uma forma esquemática e padronizada que é conhecida como **Tabela de análise de variância**, ilustrada abaixo:

Fontes de variação (FV)	Graus de liberdade (GL)	Soma de quadrados (SQ)	Quadrado médio (QM) = SQ/GL
TRATAMENTOS	$GL_{Tratamentos}$	$SQ_{Tratamentos}$	$QM_{Tratamentos}$
RESÍDUO	$GL_{Resíduo}$	$SQ_{Resíduo}$	$QM_{Resíduo}$
TOTAL	$GL_{Total}$	$SQ_{Total}$	$QM_{Total}$

O quadrado médio (QM) para cada fonte de variação é obtido pela razão entre a soma de quadrados da fonte de variação em questão pelo seus respectivos graus de liberdade.

A partir da Tabela de análise de variância podemos obter algumas estatísticas importantes de interesse prático:

**1) Coeficiente de determinação:**  $R^2 = \text{SQ}_{\text{Tratamento}}/\text{SQ}_{\text{Total}}$

Expressa proporcionalmente ou percentualmente quanto da variabilidade dos dados pode ser atribuída ao tratamento. Ou, quanto o conjunto de dados está ajustado ao modelo de análise. Importante estatística que definirá a confiabilidade dos resultados.

**2) Desvio padrão geral médio:**  $s = \sqrt{\text{QM}_{\text{Resíduo}}}$

É uma média ponderada da variabilidade das respostas dentro de cada tratamento. Ou seja, mede quanto as repetições de cada tratamento estão variando entre si.

**3) Coeficiente de variação:**  $CV = (s/\bar{y}) \cdot 100$

Obtida a partir da média geral dos  $\bar{y}$ . Essa estatística expressa percentualmente a precisão com que o experimento foi realizado. Quanto menor o valor do CV melhor é a precisão experimental. Essa precisão esta relacionada com a forma como o experimento foi instalado e conduzido.

Várias classificações de CV foram propostas por diversos autores. Uma classificação bastante usada é:

$CV < 5\%$	Muito bom (Baixo)
$5\% < CV < 10\%$	Bom (Satisfatório)
$10\% < CV < 20\%$	Regular (Intermediário)
$CV > 20\%$	Ruim (Alto)

**4) Estatística F** =  $\text{QM}_{\text{Tratamento}}/\text{QM}_{\text{Resíduo}}$

Essa estatística pode dar idéia da igualdade ou diferença estatística entre as variações de tratamentos e do resíduo. Dentro de certas condições de normalidade, homogeneidade das variâncias do resíduo e sob a hipótese que os tratamentos são iguais é possível mostrar que essa estatística tem distribuição F de Snedecor com  $[(t-1) \cdot (n-t)]$  graus de liberdade. Isso será importante para os testes de significância, que serão discutidos no item 6.

O esquema de análise de variância pode ser executado para muitas situações da experimentação. A seguir, ilustraremos numericamente algumas das possibilidades.

Consideremos um exemplo com os dados (fictícios), apresentados na Tabela a seguir, onde se supõem 4 tratamentos, 4 doses diferentes de certo produto e 2 repetições, num experimento inteiramente casualizado.

TRATAMENTO	DOSE	REPETIÇÃO	RESPOSTAS ( $y_{obs}$ )
A	1	1	8,2
A	1	2	7,8
B	2	1	9,8
B	2	2	10,4
C	3	1	12,5
C	3	2	11,5
D	4	1	10,8
D	4	2	11,2

A média geral ( $\bar{y}$ ) é calculada assim:

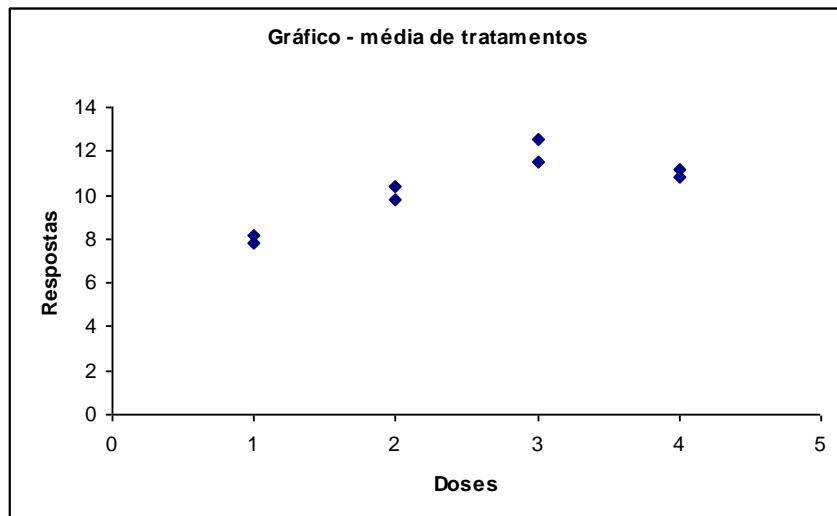
$$\bar{y} = \sum y_{obs} / n, \text{ sendo que } n \text{ é o total de observações.}$$

$$\text{Assim, } \bar{y} = (8,2 + 7,8 + 9,8 + \dots + 11,2) / 8, \text{ ou seja, } \bar{y} = 10,275$$

A  $SQ_{Total}$  pode ser obtida de duas formas diferentes:

$$SQ_{Total} = \sum (y_{obs} - \bar{y})^2 \quad \text{ou} \quad SQ_{Total} = \sum y_{obs}^2 - [\sum y_{obs}]^2 / n, \text{ assim para nosso exemplo } SQ_{Total} = 18,255$$

O gráfico de dispersão ilustra o comportamento das respostas em relação as doses ou tratamentos:



Para obtermos a  $SQ_{resíduo}$  é necessário conhecermos o desvio ou resíduo de cada observação em relação ao modelo. Supondo o modelo de médias (uma média por

tratamento), o modelo é predito pela média observada de cada tratamento e o resíduo ou desvio é chamado ERRO PURO, assim temos:

**Resposta= (média de tratamentos) + erro puro (ou resíduo)**, resultando:

TRATAMENTO	Y <sub>OBS</sub>	Y(modelo de médias)	ERRO PURO
A	8,2	8,0	0,2
A	7,8	8,0	-0,2
B	9,8	10,1	-0,3
B	10,4	10,1	0,3
C	12,5	12,0	0,5
C	11,5	12,0	-0,5
D	10,8	11,0	-0,2
D	11,2	11,0	0,2

$$\text{Então, } \text{SQ}_{\text{resíduo}} = (0,2)^2 + (-0,2)^2 + \dots + (0,2)^2 = 0,84$$

Com essas informações podemos organizar a Tabela de análise de variância:

FV	GL	SQ	QM	F
TRATAMENTOS (modelo de médias)	(t-1) = 3	17,415	5,805	27,64
ERRO PURO (resíduo)	(n-t) = 4	0,84	0,21	
TOTAL	(n-1)= 7	18,255		

Sendo t= nº de tratamentos; n= total de observações.

O CV  $[(s/\bar{y}) \cdot 100]$  obtido para essa análise foi 4,45, valor excelente considerando a Tabela de classificação geral utilizada. O  $R^2 = 0,95$  ( $\text{SQ}_{\text{Tratamento}}/\text{SQ}_{\text{Total}}$ ) indica um ótimo ajuste dos dados ao modelo.

Como podemos observar no gráfico, embora o modelo de médias de tratamentos tenha se ajustado bem aos dados, uma análise de regressão poderia ser realizada com o objetivo de mostrar mais claramente as tendências em função das doses. Em muitas situações, embora significativo, o modelo de médias de tratamentos por não informar a relação funcional com doses, pode não ser o melhor. Nesse caso, uma análise de regressão (linear, quadrática ou outra) poderia ser mais indicada.

Dessa maneira, utilizando os mesmos dados para realizar a análise de regressão quadrática (parábola), temos:

$\text{SQ}_{\text{Total}} = 18,255$  e  $\text{SQ}_{\text{resíduo}} = 1,569$ . A  $\text{SQ}_{\text{resíduo}}$  é calculada através do desvio obtido em relação a cada observação, através da substituição de cada dose na equação de ajuste do modelo parábola. Na Tabela abaixo estão apresentados os desvios.

TRATAMENTO	DOSE	$Y_{OBS}$	$Y(\text{modelo parábola})$	DESVIO
A	1	8,2	7,865	0,335
A	1	7,8	7,865	-0,065
B	2	9,8	10,505	-0,705
B	2	10,4	10,505	-0,105
C	3	12,5	11,595	0,905
C	3	11,5	11,595	-0,095
D	4	10,8	11,135	-0,335
D	4	11,2	11,135	0,065

O modelo de análise que podemos utilizar para o experimento com modelo quadrático é: Resposta = (modelo quadrático de dose) + DESVIO.

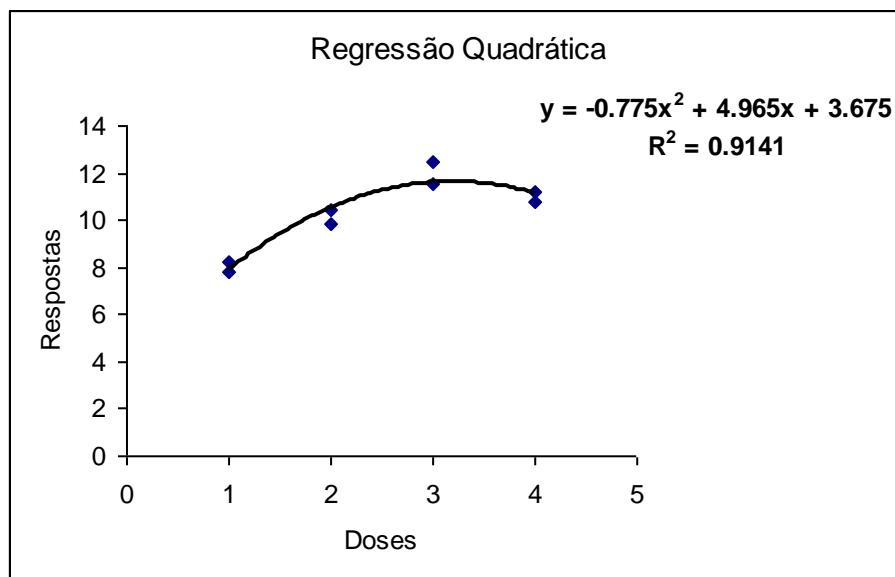
A partir daí, temos a seguinte Tabela de análise de variância:

FV	GL	SQ	QM	F
MODELO PARÁBOLA (Regressão quadrática)	2	16,686	8,343	26,59
DESVIO	(5)	1,569	0,3138	
Falta de ajuste	1	0,729	0,729	
Erro puro	4	0,840	0,210	
TOTAL	7	18,255		

Nesse caso o desvio é dado pelo erro puro mais a falta de ajuste ao modelo, assim:  
 $\text{DESVIO}(5 \text{ GL}) = \text{ERRO PURO } (4 \text{ GL}) + \text{FALTA DE AJUSTE } (1\text{GL})$ .

Para avaliar a Falta de ajuste, podemos usar a estatística  $F = 0,729/0,210 = 3,47$ , comparada com F da distribuição (tabelada) com 1 e 4 graus de liberdade, conforme será discutido no item Teste de significância. Ou usar o seu  $R^2 = 0,729/18,255 = 0,04$ , ou 4%. Ou seja, a parábola não é perfeita, mas é um modelo com  $R^2 = 91,4\%$  e com baixa falta de ajuste (4%).

Como é possível observar a primeira análise de variância realizada continua válida, mas é menos informativa. Com essa última análise e o gráfico seguinte conseguimos compreender melhor o comportamento das doses.



A equação da parábola que explica a relação entre os tratamentos e as doses é:

$y = -0,775x^2 + 4,965x + 3,675$ . O ponto de máximo calculado pela parábola é:

$$x_{\max} = (-4,965)/(2 \cdot (-0,775)) = 3,2.$$

O  $R^2 = 0,9141$ , indica um excelente ajuste dos dados à parábola. Ou seja, 91,41% da variabilidade dos dados é captada pelo modelo de regressão quadrático.

Avaliemos também o comportamento do modelo reta ou linear simples.

Supondo uma regressão linear para esses dados temos:

SQTotal = 18,255, ou seja, igual a obtida nos modelos anteriores. A SQ<sub>resíduo</sub> nesse modelo passa a ser igual a 6,374. Na Tabela abaixo estão apresentados os desvios de cada observação em relação ao modelo, necessários para o cálculo da SQ<sub>resíduo</sub>. Cada desvio é obtido pela substituição das doses na equação de ajuste do modelo linear.

TRATAMENTO	DOSE	Y <sub>OBS</sub>	Y(modelo de análise)	DESVIO
A	1	8,2	8,64	-0,44
A	1	7,8	8,64	-0,84
B	2	9,8	9,73	0,07
B	2	10,4	9,73	0,67
C	3	12,5	10,82	1,68
C	3	11,5	10,82	0,68
D	4	10,8	11,91	-1,11
D	4	11,2	11,91	-0,71

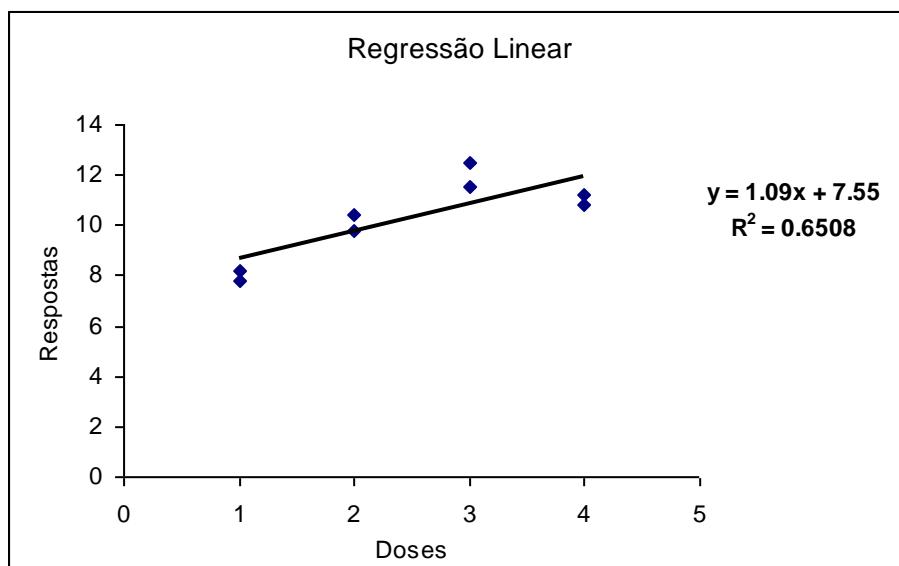
A diferença na  $SQ_{\text{resíduo}}$  ocorre devido ao resíduo ser atribuído não somente pelo erro puro como também pela falta de ajuste, que contribui com 1 GL a mais que na análise anterior. Assim: DESVIO(6 GL) = ERRO PURO (4 GL) + FALTA DE AJUSTE (2 GL).

A Tabela de análise de variância pode ser organizada da forma:

FV	GL	SQ	QM	F
MODELO RETA (Regressão linear)	1	11,881	11,881	11,18
DESVIO	(6)	6,374	1,0623	
Falta de ajuste	2	5,534	2,767	
Erro puro	4	0,840	0,210	
<b>TOTAL</b>	<b>7</b>	<b>18,255</b>		

Pode-se avaliar a Falta de ajuste, usando a estatística  $F = 2,767/0,210 = 13,17$ , comparada com F da distribuição (tabelada) com 2 e 4 graus de liberdade (isto será avaliado no item Teste de significância) ou pelo seu  $R^2 = 5,534/18,255 = 0,303$ . Ou seja, a reta embora razoável, mostra-se também com falta de ajuste significativa representativa (ou significativa conforme se verá no item Teste de significância).

O gráfico ilustra que a regressão linear responde por boa parte da variabilidade, mas também deixa falta de ajuste importante e não é um modelo bom. O  $R^2 = 0,65$  justifica essa afirmação.



Concluindo, a regressão quadrática foi o modelo que explicou melhor o comportamento das doses em relação as respostas dos tratamentos. Além de responder por porção significativa da variação existente, a falta de ajuste a esse modelo foi pequena.

## 6. ESTIMAÇÃO E TESTES DE HIPÓTESES

A partir de uma amostra ou de um experimento, os cálculos produzem o que são denominados estatísticas. Provavelmente elas não terão o mesmo valor em outro experimento. Por mais que sejam utilizados os mesmos tratamentos, será impossível obter condições ambientais e de manejo, idênticas ao que foi realizado no experimento anterior, pois há variações impossíveis de serem controladas.

Teoricamente uma estatística é uma variável aleatória. No geral, tem uma média, um desvio padrão (normalmente denominado de erro padrão) e tem uma distribuição associada. Para algumas estatísticas essas distribuições são conhecidas e por isso elas são escolhidas para permitir avaliar propriedades da estimação e/ou testes de hipóteses.

Com a amostra produz-se um valor que frequentemente pode ser usado como estimativa do valor paramétrico associado à estatística. A estimativa pode ser pontual ou por intervalo, neste último associando alguma medida de confiabilidade, que no geral irá depender da distribuição de probabilidade (distribuição amostral) associada à estatística.

Exemplo: Com uma amostra aleatória de tamanho  $n$ , as estatísticas, média  $\bar{x}_i$  e variância  $s_i^2$  podem ser usadas para estimar (estimador) a média e a variância populacional (desconhecidas). Esses valores são estimativas pontuais. Usando propriedades dessas estatísticas é possível construir o usual intervalo em que se confia que esteja o verdadeiro valor da média populacional:  $[\bar{x}_i - t s/n^{1/2}; \bar{x}_i + t s/n^{1/2}]$ , ou seja uma estimativa por intervalo.. Na fórmula  $t s/n^{1/2}$  é o erro da estimativa da média,  $s/n^{1/2}$  é o erro padrão da média e o valor de  $t$ , distribuição  $t$  de Student (tabela no final do texto), associado a estatística, dará a confiança do intervalo ( $t \sim 2$ , para 95% de confiança). Note que é um intervalo em que se confia que a média estará, nunca saberemos se realmente está! Esse é um conceito fundamental, que frequentemente deixará dúvida ao iniciante.

Os testes de hipóteses (também conhecidos como testes de significância) são realizados com o objetivo de determinar o grau de aceitação de hipóteses baseadas em estatísticas, cuja distribuição amostral é conhecida ou construída por algum processo de reamostragem. Uma outra estatística que será importante, na sequência, é a F produzida na análise de variância. Demonstra-se que sob certas condições ela terá distribuição F de Snedecor (tabela no final do texto), o que permitirá a construção de testes de hipóteses, como a seguir.

Mas em que consistem os testes de hipóteses ou de significância?

De maneira genérica, a realização de testes de significância envolve algumas etapas ou procedimentos, mais ou menos obrigatórios::

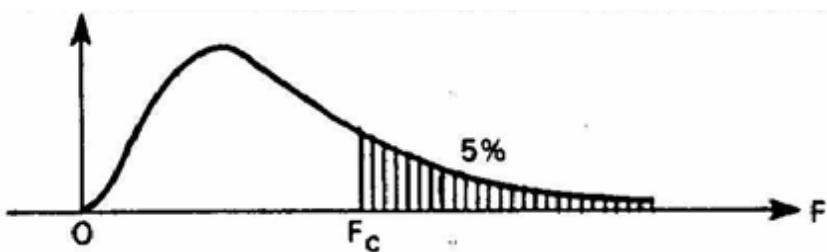
- 1) Definir uma hipótese nula ( $H_0$ );
- 2) Escolher uma estatística que tenha uma distribuição conhecida sob  $H_0$ . No geral, chamamos de distribuição de referência associada à estatística;
- 3) Definir um tamanho de amostra ( $n$ );
- 4) Definir uma região de rejeição em que a estatística, mesmo sob  $H_0$  possa estar lá com probabilidade pequena. Essa probabilidade é no máximo ( $\alpha$ ) e é denominada nível de significância do teste;
- 5) Calcular o valor da estatística, utilizando os valores obtidos na(s) amostra(s). ou no experimento. Se tal valor estiver na região de rejeição, rejeitar a hipótese nula, senão, a decisão será que a hipótese nula não poderá ser rejeitada, ao nível de significância estabelecido.

Para melhor entendimento, vamos discutir o teste F, realizado na análise de variância.

Supondo o modelo com uma média por tratamento e a igualdade de médias ( $H_0$ ), se não houvesse variação aleatória, as médias amostradas de cada tratamento seriam todas iguais e iguais à média geral. Portanto a  $SQ_{Tratamentos} = \sum(\bar{y}_i - \bar{y})^2 = 0$

No entanto, na prática existe variabilidade e o valor F calculado será maior que ZERO. A estatística F é calculada através da razão  $QM_{Tratamento}/QM_{Resíduo}$ .

Quanto maior for a estatística F, menor a chance desse valor acontecer sob a hipótese de um modelo de efeito nulo (igualdade de tratamentos). Ou seja, o valor de F deve ser grande (maior que o  $F_c$  tabelado, em nível  $\alpha$  de significância) para rejeitar  $H_0$  e concluir pela diferença significativa entre algum contraste de médias de tratamentos. Quando isso ocorre ( $F \geq F_c$ ) dizemos que o valor da estatística “caiu” na região crítica. Na Figura a seguir podemos observar a região crítica para a distribuição F de Snedecor, para nível de significância ( $\alpha = 0,05$ ) ou 5%. A região crítica é formada por valores maiores que  $F_c$  (valor F crítico ou F tabelado para o correspondente nível de significância de interesse).



No caso da análise de variância, rejeitar  $H_0$  significa acreditar que o modelo nulo não é correto. Dessa forma, podemos dizer que o modelo não nulo responde por porção significativa da variação existente (estimada pelo  $R^2$ ). No geral também não podemos afirmar com 100% de certeza que esse modelo seja correto.

Ainda existe a possibilidade que o modelo nulo seja verdadeiro. Essa possibilidade é no máximo igual ao tamanho da região crítica. Na agropecuária, é usual trabalhar com  $\alpha=5\%$ , (ou seja, desde que a hipótese nula seja rejeitada, a chance de erro será de no máximo 5%). Na prática, dependendo do caso, pode-se usar valores maiores. Os programas estatísticos no geral calculam um valor, chamado “p-value”, que é a probabilidade de valores maiores que a estatística, por simples acaso. Esse valor será o tamanho do erro, chamado tipo I, se a hipótese  $H_0$  for rejeitada.

Quando o valor da estatística “cai” fora da região crítica ( $F < F_c$ ) não rejeitamos  $H_0$ , ou seja, aceitamos que o modelo nulo seja o correto (na prática, não existe efeito de tratamentos).

Mas será isso verdade?

Não necessariamente, e a chance disso acontecer chama-se erro tipo II. O cálculo desse erro depende de qual hipótese alternativa à  $H_0$  é verdadeira (no geral é difícil de calcular). Esse erro é muito comum quando usamos amostras ou delineamentos não adequados, ou seja, não rejeitamos  $H_0$  por deficiência do delineamento experimental.

Por isso, na prática costuma-se dizer que é perigoso concluir pela igualdade dos tratamentos, exceto quando se trabalha com amostras e delineamentos muito bons. Estatisticamente é mais seguro concluir que o delineamento não permitiu detectar diferenças entre os tratamentos do que dizer que os tratamentos foram iguais.

Quando o CV for baixo e o grau de liberdade do resíduo for grande, existe forte evidência de que não estamos cometendo o erro do tipo II. Daí a importância dos delineamentos experimentais e de análises estatísticas adequadas.

Os Erros do tipo I e do tipo II e como podem ser ocasionados estão ilustrados na Tabela a seguir:

Conclusão do teste	Situação específica na população	
	$H_0$ verdadeira	$H_0$ falsa
Não rejeitar $H_0$	Decisão correta	<b>Erro tipo II</b>
Rejeitar $H_0$	<b>Erro tipo I</b>	Decisão correta

Como vimos na análise de variância, a estatística F é usada para testar se o modelo responde ou não por porção significativa da variação existente.

Caso seja detectada a diferença entre os tratamentos, por exemplo, no modelo de uma média por tratamento (usado especialmente no DIC), a significância do valor F implica que nem todas médias são iguais.

Mas então vêm as perguntas: Qual é ou são a(s) diferentes(s)? Qual é o melhor tratamento? E o pior?

Há várias técnicas para responder essas perguntas.

Uma maneira bastante usual é utilizar os PPCM (procedimentos para comparações múltiplas), que serão discutidos a seguir.

### **Outros testes – PPCM (procedimentos para comparações múltiplas)**

Em que consistem os PPCM?

A regra é aparentemente simples. Consiste em estabelecer uma quantidade mínima significativa, denominada DMS (diferença mínima significativa). Se a diferença entre duas médias (em módulo) superar a DMS, a conclusão é que as duas médias diferem entre si.

Usando a terminologia adaptada de O'Neill & Wetherill (1971), usa-se:  $DMS = q \times epm$ , onde  $q$  é um valor tabelado, no geral é o valor esperado de uma amplitude padronizada em função das médias envolvidas e  $epm$  é o erro padrão das médias (suposto o mesmo ou uma média deles).

Vamos ilustrar um caso simples, comparando 2 tratamentos.

Supondo:

$$\text{Média A (Ma)} = 20$$

$$\text{Média B (Mb)} = 24 \text{ (diferença observada entre as médias é igual a 4)}$$

$$QM_{\text{Resíduo}} = 2$$

$$r = n^{\circ} \text{ de repetições} = 4$$

$$GL_{\text{resíduo}} = 6$$

$$epm = \frac{\sqrt{QM_{\text{resíduo}}}}{\sqrt{r}} = 0,71$$

$$q_2 = 3,46 \text{ (valor tabelado para 2 médias e } 6 GL_{\text{Resíduo}})$$

Então, a DMS mínima, também conhecida como LSD (least difference significance) é:

$$LSD = q_2 \times epm = 3,46 \cdot 0,71 = 2,76$$

Portanto como a diferença observada (4) é maior que a LSD (2,46), as médias são estatisticamente diferentes.

A LSD (menor DMS) é exata para experimentos de comparação entre duas médias. Para comparação de mais médias é uma medida “frouxa”, pois podem ser detectadas

comparações significativas, que de fato não são. As comparações usando LSD é o chamado teste t ou teste de Student.

Agora, um exemplo com 5 tratamentos. Supondo 5 tratamentos temos:

$$QM_{\text{Resíduo}} = 4$$

$$r = \text{nº de repetições} = 4$$

$$GL_{\text{resíduo}} = 15$$

$$epm = \frac{\sqrt{QM_{\text{resíduo}}}}{\sqrt{r}} = 1$$

Na Tabela a seguir temos apresentadas as médias dos 5 tratamentos e o ranking de classificação (ordenamento) das médias dos tratamentos:

Médias	Valores	Ranking das Médias
Ma	1	5º
Mb	7	4º
Mc	12	1º
Md	8	3º
Me	9	2º

Para esse caso poderíamos ainda usar a LSD , ou teste t, usando:

$$q_2 = 3,01 \text{ (valor tabelado para 2 médias e } 15 GL_{\text{Resíduo}})$$

$$LSD = q_2 \times epm = 3,01 \cdot 1 = 3,01.$$

Ou como é também comum, usar a DMS máxima, também conhecida como HSD (honestly significance difference) que é o teste Tukey, calculado com:

$$q_5 = 4,37 \text{ (valor tabelado - t médias, no caso 5 e } 15 GL_{\text{Resíduo}})$$

$$HSD = q_5 \times epm = 4,37 \cdot 1 = 4,37$$

$$Mc - Ma = 12 - 1 = 11, \text{ assim } 11 > 4,37$$

Portanto como a diferença entre a maior e a menor média (amplitude) é maior que a HSD, podemos concluir que existe diferença entre essas duas médias.

A HSD (maior DMS) é exata para comparar diferenças entre a maior e a menor média de um grupo de tratamentos. Para outras comparações é uma medida conservadora, pois pode não detectar diferenças significativas que de fato existem. Na prática, é muito eficiente para eliminar as piores médias.

Preferencialmente, os tratamentos devem ter o mesmo número de repetições, pois caso contrário, cada média de tratamento terá um epm (erro padrão da média) diferente.

Nesse caso, os tratamentos com menos repetições podem apresentar médias menos confiáveis e para aplicação do teste utilizam-se epm médios.

Usualmente apresentamos os resultados do teste de Tukey em Tabelas, onde as médias são ordenadas de forma decrescente, de forma que letras iguais indicam médias não significativamente diferentes e letras diferentes indicam diferenças significativas, ao nível  $\alpha$  de significância estabelecido na escolha do valor tabelado  $q_t$ .

A seguir, um exemplo da aplicação do teste Tukey em um experimento de seleção de progênies , instalado em DIC, com 4 repetições.

Na Tabela a seguir estão apresentados dados de parcelas de um experimento de 10 progênies, com 4 repetições clonadas via enraizamento de estacas (usual em cana-de-açúcar, mandioca, eucalipto, frutíferas e outras espécies).

Progênies	P1	P2	P3	P4	P5	P6	P7	P8	P9	P10	Total
	16,0	14,3	14,7	13,6	11,6	11,0	13,1	10,3	8,5	8,2	
	16,4	14,5	15,6	13,1	10,5	15,0	10,3	13,2	8,6	8,4	
	14,1	13,8	11,6	14,7	15,9	10,7	14,3	10,2	9,5	9,3	
	11,7	14,6	15,0	15,1	14,0	13,0	10,5	13,0	9,4	9,2	
Total	58,2	57,2	56,9	56,5	52,0	49,7	48,2	46,7	36,0	35,1	496,5
Média	14,55	14,30	14,22	14,12	13,00	12,42	12,05	11,67	9,00	8,80	

A partir desses dados podemos construir a seguinte tabela de análise de variância:

FV	GL	SQ	QM	F
Progênies (tratamentos)	9	160,98	17,89	6,91**
Resíduo	30	77,56	2,59	
Total	39	238,54		

Como:

$$s = \sqrt{QM_{\text{Resíduo}}} = \sqrt{2,59} = 1,61$$

$$q(t; GL_{\text{Resíduo}}) = q(10; 30) = 4,82$$

$$\text{epm} = \frac{\sqrt{QM_{\text{resíduo}}}}{\sqrt{r}} = 1,61 / \sqrt{4} = 0,805$$

Pelo teste de Tukey temos:

$$HSD = q_{10} \cdot \text{epm} = 4,82 \cdot 0,805 = 3,88$$

$$\text{Amplitude} = (\text{maior média}) - (\text{menor média}) = 14,55 - 8,80 = 5,75$$

Como a amplitude observada ( $= 5,75$ )  $>$  HSD ( $=3,88$ ), pode concluir que existe diferença significativa para esse contraste de médias (maior média – menor média).

Agora podemos organizar em ordem decrescente as médias dos tratamentos, para maior facilidade de comparação, e usar a mesma HSD. Os resultados podem ser resumidos pelas letras colocadas ao lado das médias. Letras iguais indicam diferenças não significativas, ao nível de significância dado pela HSD, e letras diferentes indicam diferenças significativas a esse nível de probabilidade.

	Progênies	Médias
P1	14,55	A
P2	14,30	A
P3	14,22	A
P4	14,12	A
P5	13,00	A
P6	12,42	A B
P7	12,05	A B
P8	11,67	A B
P9	9,00	B
P10	8,80	B

No caso, entre as progênies de 1 a 5 não existem diferenças significativas para PE. As progênies de 1 a 8 possuem médias de PE significativamente maiores que as progênies 9 e 10. As progênies 6, 7 e 8 formam um grupo intermediário.

Portanto, para uma seleção onde se preferem progênies com respostas maiores seriam selecionados as progênies 1 a 5.

Além dos testes t (LSD) e Tukey (HSD), dezenas de outros PPCM, também são utilizados para tal fim. Entre eles: Duncan, Dunnett, Shefée, SNK. Cada um deles apresentam vantagens e desvantagens ( O'Neill & Wetherill, 1971; Perecin & Barbosa, 1988, Perecin & Malheiros, 1989; discutem bem isso).

## 7. DELINEAMENTOS EXPERIMENTAIS

Existem delineamentos estatísticos adequados para levantamentos amostrais ou para realização de experimentos planejados (delineamentos experimentais). São formas ou métodos eficientes para se amostrar adequadamente e obter respostas de interesse para avaliar, provar ou não hipóteses em consideração. Trataremos aqui especificamente de alguns dos principais delineamentos experimentais.

Durante o planejamento do experimento, a escolha do delineamento deve ser feita basicamente em função da homogeneidade das parcelas experimentais, da área que se tem disponível para a realização do experimento (campo, casa de vegetação, laboratório, etc.), dos objetivos da pesquisa e dos materiais disponíveis para realização do experimento. Alguns pontos fundamentais ao construir os delineamentos experimentais necessariamente devem ser avaliados e são enfatizados a seguir.

### **Repetição e casualização**

Especialmente em experimentos de campo os materiais (tanto tratamentos como genótipos) estão sujeitos as variações de diversas naturezas: solo, fertilidade e adubações, pragas e doenças etc. Para poder compensar os efeitos dessas variabilidades típicas das culturas no campo, os experimentos devem ser implantados com repetições e essas devem ser casualizadas. Sem isso, um material ou tratamento poderá ser alocado em um nicho particular do terreno, sendo então beneficiado ou prejudicado.

### **Parcela**

A parcela é constituída pela área (ou canteiro) em que cada repetição do tratamento é alocado. As parcelas devem ser preferencialmente todas do mesmo tamanho. Sem isso haverá heterogeneidade da variância, o que não é desejável. No geral, com culturas, são constituídas de 4 a 8 linhas e com comprimento preferencialmente maior que a largura. Ao fazer a extração para 1 hectare, o fator de multiplicação é no geral superior a 100. Portanto, uma diferença de apenas 1m na parcela, seja por falha ou por problemas de instalação, pode representar bom percentual em termos da produção expandida para hectare.

Trabalhos experimentais com várias culturas demonstram que no geral é mais conveniente reduzir o tamanho da parcela e aumentar o número de repetições, do que fazer parcelas grandes com menos repetições.

### **Bordadura e área útil**

Para que não haja influência de fatores de borda, especialmente maior luminosidade, ventos e competição por luz e nutrientes com material na parcela adjacente, é necessário separar a bordadura e colher só materiais da área útil da parcela. Para isso toda área experimental deve ser plantada com bordadura, especialmente parcelas de borda.

A não observância desse fato pode aumentar a variabilidade , subjetivamente avalia-se em mais de 30%. Ainda, devido as dificuldades práticas, é preciso muita atenção para não misturar linhas de materiais ou tratamentos diferentes ou mesmo da bordadura, na hora da colheita.

### **Estande da cultura**

O problema do estande pode ser sério, por exemplo, no plantio tradicional da cana-de-açúcar e não há uma maneira segura de fazer correção. Análises de covariância e outras técnicas de correção de estande dificilmente melhoram os resultados. Alguns genótipos fazem certa correção do estande por si só, através do perfilhamento ou brotação; outros genótipos não tem essa capacidade, o que complica qualquer tentativa de correção.

### **Importância do conceito de bloco**

O Bloco não pode ser confundido com repetição. O Bloco tem que ser entendido como um conjunto de parcelas uniformes, quanto a sua disposição no campo, no geral na mesma curva de nível, e também uniforme para outros fatores. O ideal é que tanto o plantio como a colheita sejam feitos por Bloco, pois isso manterá a uniformidade. Não há problemas se o plantio ou se a colheita de um Bloco como um todo não for processado no mesmo dia, mas pode alterar a uniformidade, se isso acontecer em só parte do Bloco .

O Bloco pode ser completo com uma ou mais repetição de cada genótipo, embora o usual seja uma repetição; mas pode ser incompleto faltando tratamentos (exemplo, blocos de Federer e outros delineamentos similares). Esses delineamentos também conhecidos como blocos aumentados, são muito usuais nas fases iniciais do melhoramento de várias culturas. As variedades padrões ou testemunhas são instaladas em blocos casualizados completos e cada bloco recebe um número adicional de genótipos novos ou clones (uma ou mais repetições, dependendo da disponibilidade de material). Na análise estatística haverá ajustes, os tratamentos que ficam nos melhores blocos serão penalizados e os que ficam nos piores blocos serão bonificados; exigindo comparações ajustadas.

### 7.1) Delineamento inteiramente casualizado (DIC)

É o delineamento mais simples. Para ser utilizado exige que todas as parcelas experimentais sejam homogêneas. As condições ambientais também deverão ser as mais uniformes possíveis, a fim de que, o único componente que possa vir a sofrer variação de uma parcela para outra, sejam os tratamentos. É um delineamento com um só bloco.

Por essa razão, normalmente esse tipo de delineamento é aplicado em experimentos realizados em laboratório ou casa de vegetação, por ser mais fácil o controle do ambiente.

Em laboratório, a umidade, temperatura e outros fatores deverão ser constantes e o técnico que conduzirá o experimento deverá ser preferencialmente o mesmo, a fim de evitar variação entre as parcelas.

Da mesma forma, se o experimento for realizado em vasos, numa casa de vegetação, todos os vasos deverão ser iguais, preenchidos com o mesmo substrato, ser submetido à mesma irrigação, etc. É conveniente também, a cada certo intervalo de tempo, promover um rodízio entre os vasos, para que todos sejam submetidos às mesmas condições ambientais.

Caso o experimento seja realizado em uma área de campo, esta deve ser homogênea, ou seja, possuir mesmo tipo de solo e igual fertilidade em toda sua extensão, além de receber mesmo tratamento (adubação, irrigação, etc.), exceto se alguns desses fatores forem os tratamentos em teste.

Exemplo: Se desejarmos comparar a preferência de uma praga "X" por 4 variedades de cana-de-açúcar (Tratamentos: Va, Vb, Vc, Vd), podemos instalar vasos com as diferentes variedades em uma casa de vegetação e submetê-las ao ataque da praga, a fim de comparar os resultados. Supondo 5 repetições (1, 2, 3, 4, 5), um possível croqui do sorteio dos tratamentos será:

1 Vb	5 Vd	3 Va	4 Vb	5 Va
4 Vc	5 Vc	1 Vd	2 Va	3 Vd
1 Va	2 Vd	3 Vc	2 Vb	4 Vd
2 Vc	3 Vb	4 Va	1 Vc	5 Vb

Nesse caso, em um experimento com 4 tratamentos e 5 repetições, teremos 20 parcelas homogêneas, onde os tratamentos e repetições deverão ser sorteados aleatoriamente na área experimental (no caso, vasos).

Dessa forma se tudo estiver adequado, esse é o delineamento perfeito e os tratamentos terão condições de manifestar seus verdadeiros efeitos, sem a influência ambiental.

Um possível modelo para análise, de forma esquemática, será:

**Resposta= média de tratamentos + resíduo.**

E uma possível análise de variância (ANOVA) para o exemplo, será:

## UMA ANOVA PARA O DIC

FONTES DE VARIAÇÃO	GRAUS DE LIBERDADE
TRATAMENTOS	$4-1=3$
RESÍDUO	$(5-1)*(4)=16$
TOTAL	$20-1=19$

Os resíduos conterão todos demais efeitos, especialmente biológicos e ambientais, não contidos no efeito de cada tratamento.

Para alguns testes estatísticos é desejável que a variância dos resíduos dentro de cada tratamento sejam homogêneas, possuam distribuição normal, sejam independente entre elas e também dos tratamentos. Na prática, no geral essas condições são satisfeitas, pelo menos aproximadamente, e só em casos mais específicos haverá restrições. A questão de homogeneidade da variância, discutida no Anexo 2, é a principal exigência, pois os erros padrões são obtidos com a média das variâncias.

Comparado com delineamentos mais complexos, o DIC apresenta algumas vantagens tais como:

- Qualquer número de tratamentos ou repetições pode ser usado: o número de repetições também pode variar de um tratamento para outro, intencionalmente (pela falta de parcelas ou material) ou por acidente (morte de planta = perda de parcela), sem que isso dificulte a análise. No entanto, devemos preferir usar o mesmo número de repetições para todos os tratamentos, para que a média dos tratamentos (estatística) tenha o mesmo erro padrão.
- O número de graus de liberdade do erro experimental (resíduo) é o maior possível, com o número de parcelas empregado. Este fato implica em maior precisão do experimento quando as parcelas são uniformes.

## **7.2) Delineamento em blocos completos casualizados (DBC)**

O delineamento em blocos completos com tratamentos casualizados nos blocos, abreviadamente denominado de blocos ao acaso (DBC), caracteriza-se por possuir blocos. Especificamente neste texto, trataremos do DBC com uma única repetição de todos os tratamentos, casualizados dentro de cada bloco, ou seja, dessa forma o número de repetições será igual ao número de blocos.

Como já vimos, bloco é um subconjunto de parcelas homogêneas, em que os tratamentos deverão manifestar seus efeitos de forma independente do bloco e de forma aditiva. Por exemplo, parcelas numa mesma altitude (curva de nível), árvores de mesma altura, espécie ou diâmetro, etc.

Em princípio, os blocos podem diferir entre si em menor ou maior grau. No entanto, tais diferenças não podem causar interação entre os blocos e os tratamentos, porque essa

interação irá inflacionar o erro experimental e reduzir a precisão do experimento. Teoricamente se um tratamento se comportar melhor em um determinado bloco, é conveniente que esse mesmo tratamento seja melhor em todos os blocos.

Devido as suas características, como a facilidade de instalação, separação de cada repetição em um bloco, além da realização de grande parte dos experimentos agrícolas serem realizados no campo (geralmente em áreas heterogêneas, separadas por curvas de nível, devido a declividade), o DBC é o delineamento mais utilizado na experimentação agrícola.

Tomando o mesmo exemplo anterior, se agora quisermos testar as 4 variedades (Tratamentos: Va, Vb, Vc, Vd), no campo e vamos ter novamente 5 repetições, há necessidade de 5 conjuntos (blocos) de parcelas homogêneas dentro de cada bloco. O esquema adiante ilustrará essa situação.

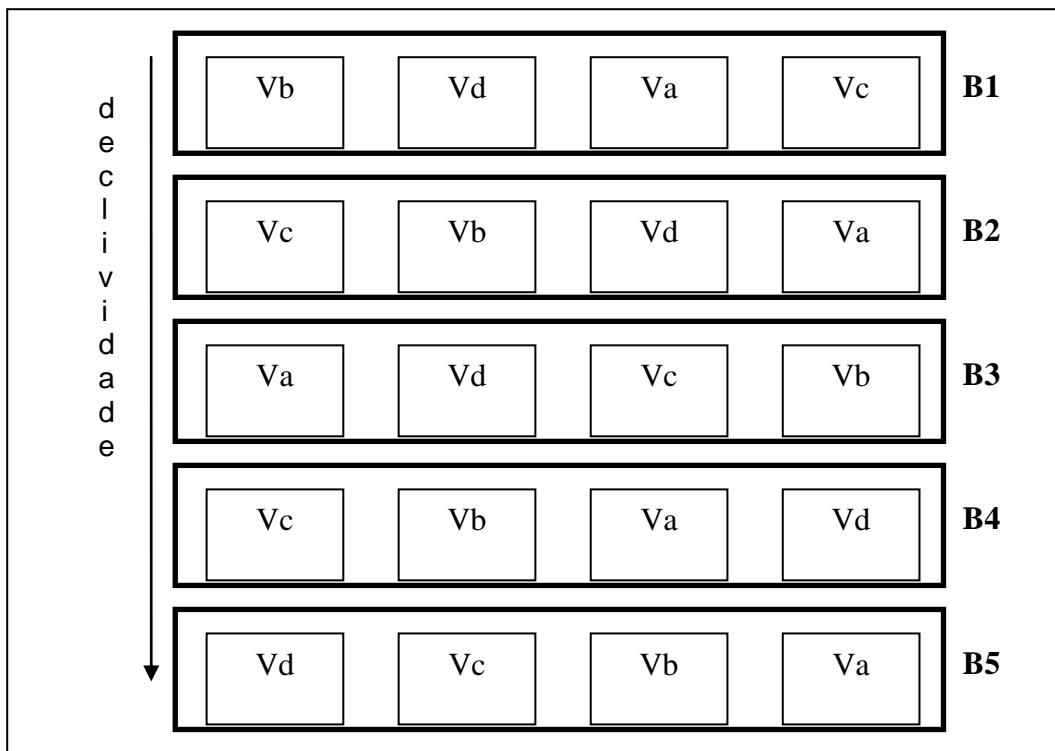
Os tratamentos deverão ser sorteados aleatoriamente dentro de cada bloco, então teremos de realizar 5 sorteios diferentes. E no caso de experimentos instalados em área de campo, os blocos devem ser formados por parcelas paralelamente à curva de nível, com as linhas de plantio, tratos culturais, colheita, etc. também dispostos paralelamente à curva de nível.

Se o experimento for instalado em laboratório, por exemplo, o bloco poderá ser o operador, o aparelho medidor ou cada dia em que os resultados forem medidos.

Há muitas outras situações, em que poderemos utilizar blocos. O importante é ter o conceito de bloco refletido com muito cuidado.

Na prática agrícola é usual usar a expressão controle local, para definir um delineamento que seja instalado com blocos.

Exemplo de um croqui no campo, com quatro variedades e cinco blocos:



Um possível modelo de análise, de forma esquemática, será:

**Resposta= média de tratamentos + efeito de blocos + resíduo.**

Nesse esquema fica clara a necessidade de aditividade entre tratamentos e blocos (os termos do modelo são somados). Qualquer falta de aditividade irá inflar os resíduos. Por isso o uso de blocos, quando necessário, se faz tão importante.

Na análise exploratória de dados, é fácil desconfiar da falta de aditividade, fazendo um gráfico em linha, onde se plota nos eixos da abscissa os blocos (B1, B2, ..., B5) e nas ordenadas as respostas dos tratamentos (uma linha por bloco). Sob aditividade haverá paralelismo das respostas, de bloco para bloco. Quando as linhas se cruzam, há fortes evidências da falta de aditividade. Na literatura há testes estatísticos para avaliar isso.

Um esquema da ANOVA, para o exemplo, será:

## UMA ANOVA PARA O DBC

FONTES DE VARIAÇÃO	GRAUS DE LIBERDADE
BLOCO	$5-1=4$
TRATAMENTOS	$4-1=3$
RESÍDUO	$(5-1)*(4-1)=15$
TOTAL	$20-1=19$

### 7.3) Delineamento em quadrado latino (DQL)

Este delineamento permite o controle da heterogeneidade entre as parcelas quanto a dois fatores Blocos interferentes. Assim, o conceito de bloco é aplicado duas vezes. É como se as parcelas fossem agrupadas segundo uma tabela de dupla entrada, em que uma classifica quanto aos níveis do fator “A” de heterogeneidade e outra classifica quanto aos níveis do fator “B” de heterogeneidade. Cada fator deve ter o mesmo número de níveis. Ou seja, o número de linhas e o número de colunas da tabela devem ser iguais e iguais ao número de tratamentos, que deve estar balanceadamente em toda linha e toda coluna.

Exemplo: Seja, por exemplo, um experimento no campo, em que cada parcela é constituída por 5 plantas de *Citrus sp.* (A, B, C, D, E). E as plantas variam quanto a idade (fator A) e a forma de poda (fator B). Ou seja, se tivermos 5 diferentes tipos de poda e 5 idades diferentes, as respostas podem ser analisadas por DQL (5x5). Croqui no campo:

DQL	PODA 1	PODA 2	PODA 3	PODA 4	PODA 5
IDADE 1	C	A	B	D	E
IDADE 2	E	C	A	B	D
IDADE 3	D	E	C	A	B
IDADE 4	B	D	E	C	A
IDADE 5	A	B	D	E	C

Teremos então 25 parcelas experimentais, ou seja, 5 idades e 5 formas de poda, nas quais podemos avaliar 5 tratamentos. Os tratamentos deverão ser sorteados nas linhas e nas colunas, de modo que todos os tratamentos estarão em todas as linhas e em todas as colunas, de forma balanceada.

O fato de o número de tratamentos ser igual ao número de repetições é uma limitação ao uso deste delineamento, pois, ao usarmos 8 ou mais repetições poderemos ter um número exagerado de repetições. Com 4 tratamentos ou menos poderemos ter um número insuficiente de repetições, embora, nesse caso possamos repetir o quadrado latino duas ou mais vezes (ver item 9).

Este delineamento é, muitas vezes, utilizado para eliminar a variação (heterogeneidade) do solo em duas direções perpendiculares (linhas numa direção e colunas na direção perpendicular), considerando-se a localização topográfica das parcelas. Isso acontece normalmente em solos baixos, onde se usam drenos em duas direções, ou que tenham influência de ventos, rios, matas, etc.

Verificamos, no esquema do experimento acima, que para cada classe de idade e forma de poda aplicou-se uma vez cada tratamento, portanto, cada idade e forma de poda constitui um bloco. Há, neste caso, um duplo bloqueamento ou duplo controle local e portanto, duas restrições na casualização dos tratamentos nas parcelas. Assim o controle local desse delineamento é mais rigoroso que no DBC.

Um possível modelo esquemático, para explicar o DQL, nesse exemplo, será:

**Resposta= média de tratamentos + efeito de linha (idade) + efeito de coluna (poda) + resíduo.**

O esquema da ANOVA, para o exemplo, será:

## ANOVA DO DQL (5\*5)

FONTES DE VARIAÇÃO	GRAUS DE LIBERDADE
BLOCO (linha)	$5-1=4$
BLOCO (coluna)	$5-1=4$
TRATAMENTOS	$5-1=4$
RESÍDUO	$(5-1)*(5-2)=12$
TOTAL	$25-1=24$

### 7.4) Outros delineamentos

Os delineamentos discutidos anteriormente (DIC, DBC, DQL) são os mais simples e utilizados, mas existem outros delineamentos específicos, que as vezes são necessários, principalmente quando o número de tratamentos é muito grande, e fica difícil organizar blocos com parcelas homogêneas. O bloco pode ser completo com uma ou mais repetição de cada genótipo, embora o usual seja uma repetição; mas pode ser incompleto faltando genótipos ou tratamentos (exemplo, blocos de Federer e outros delineamentos similares). Esses delineamentos também conhecidos como blocos aumentados, são muito usuais nas fases iniciais do melhoramento da cana, por exemplo. As variedades padrões ou testemunhas são instaladas em blocos casualizados e cada bloco recebe um número adicional de clones (uma ou mais repetições, dependendo da disponibilidade de material). Na análise estatística haverá ajustes, os clones que ficam nos melhores blocos serão penalizados e os que ficam nos piores blocos serão bonificados; exigindo comparações ajustadas, ver Scott e Milliken (1993).

Há ainda outros delineamentos em blocos incompletos, que podem ser: balanceados, parcialmente balanceados ou não balanceados, látices e outros.

Caso existam mais de um fator a ser analisado podem surgir delineamentos ainda mais complexos, por exemplo : delineamento em parcelas subdivididas, delineamento em blocos divididos (faixas). Na literatura a discussão sobre isso é farta.

### **Limitação prática para o tamanho do bloco**

Em experimentos de campo, os Blocos no geral não devem ter mais que 20 a 30 tratamentos, pois começa aparecer interação genótipo por ambiente (GxE), ou seja, teoricamente o mesmo tratamento teria respostas diferentes, conforme a posição no bloco (perda da aditividade, já referida)..

Para essa situação DBC não é um bom delineamento! Algumas alternativas são

### **Grupos com tratamentos comuns.**

Exemplo: Suponha o caso em que há 45 (1 a 45) genótipos novos para comparar e temos quatro cultivares (A, B, C e D), como padrões ou testemunhas e deseja fazer duas repetições. Fazer blocos com 49 parcelas, no geral não é adequado e uma estratégia melhor é fazer blocos com 19 parcelas, com se seguem:

Sortear no Bloco 1: A, B, C, D, 1, 2, ..., 15

Sortear no Bloco 2: A, B, C, D, 1, 2, ..., 15

Sortear no Bloco 3: A, B, C, D, 15, 16, ..., 30

Sortear no Bloco 4: A, B, C, D, 15, 16, ..., 30

Sortear no Bloco 5: A, B, C, D, 31, 32, ..., 45

Sortear no Bloco 6: A, B, C, D, 31, 32, ..., 45

O esquema da ANOVA, para o exemplo, será:

## ANOVA GRUPOS COM COMUNS

FONTES DE VARIAÇÃO	GRAUS DE LIBERDADE
GRUPOS OU "SETS"	G-1, NO CASO (3-1=2)
BL.(DENTRO DE GR.)	(2-1)+(2-1)+(2-1)
GENÓTIPO(AJUST.)	49-1=48
INT. COMUNS X GR.	(4-1)*(3-1)
RESÍDUO(D.GR.)	18+18+18
TOTAL	114-1=113

### Blocos aumentados

É um delineamento usado, no geral, quando não há mudas ou sementes ou áreas suficientes para se fazer repetições dos genótipos novos.

Exemplo: Suponha o caso em que há 45 (1 a 45) genótipos novos para comparar e temos quatro cultivares (A, B, C e D), como padrões ou testemunhas, e não há possibilidade de fazer repetições dos genótipos novos. Uma estratégia é fazer blocos completos com os padrões e em cada bloco incluir genótipos novos, ver análises em Scott & Milliken (1993). Por exemplo, com 13 parcelas o delineamento pode ser como se segue:

Sortear no Bloco 1: A, B, C, D, 1, 2, ..., 9.

Sortear no Bloco 2: A, B, C, D, 10, 11, ..., 18.

Sortear no Bloco 3: A, B, C, D, 19, 20, ..., 27.

Sortear no Bloco 4: A, B, C, D, 28, 29, ..., 36.

Sortear no Bloco 5: A, B, C, D, 37, 38, ..., 45.

Um cuidado, o resíduo só é estimado com os padrões. Um esquema da ANOVA, para o exemplo, será:

## ANOVA BLOCOS AUMENTADOS

FONTES DE VARIAÇÃO	GRAUS DE LIBERDADE
BLOCO	$5-1=4$
GENÓTIPO (AJUST.)	$49-1=48$
RESÍDUO COMUNS	$(5-1)*(4-1)=12$ (CUIDADO!)
TOTAL	$65-1=64$

Outras opções menos usuais, devido menor a flexibilidade de instalação, são os BIB (blocos incompletos平衡ados) e os Lattices.

### Experimentos com parcelas grandes

Algumas técnicas empregadas no manejo, preparo do solo ou colheita da cultura, podem exigir parcelas grandes para a sua própria execução. Com isso, se forem feitas todas repetições necessárias, o experimento pode ficar muito grande e por problemas de custo ou de uniformidade da área, inviável.

Uma alternativa, é a subdivisão da parcela grande em subparcelas menores. Estas serão então colhidas de forma separada. Na análise estatística serão levadas em conta a variabilidade experimental (entre parcelas grandes) e a variabilidade amostral entre subparcelas (dentro). Freqüentemente as relações entre essas variabilidades são não grandes. Nesse caso, elas funcionam como “repetições” e as variabilidades experimental e amostral

podem ser reunidas, aumentando a representatividade das variações ambientais. Quando a variabilidade experimental (entre) for muito maior que a variabilidade amostral (dentro) é forte indicador de que o conceito de bloco não foi adequadamente aplicado. O contrário (maior variabilidade amostral) é forte indicador da não adequação ou da representatividade da subparcela amostrada.

### **Número de repetições**

O número de repetições depende basicamente da diferença que se quer detectar e/ou do parâmetro que se quer estimar. Quanto menor a diferença que se quer detectar, maior o número de repetições e isso pode ser calculado caso a caso.

De modo geral, para razoável estimação das variações ambientais, que servirão para estimar o erro padrão associado às médias, o experimento não pode ser muito pequeno (o usual é um mínimo de 20 parcelas) e também o grau de liberdade associado à variação ambiental ou Resíduo também não pode ser muito baixo (o usual é exigir um mínimo de 10).

É mais ou menos clássico na experimentação, que é mais eficiente aumentar o número de repetições e diminuir o tamanho da parcela do que o contrário. Embora, a diminuição do tamanho da parcela em função dos efeitos de borda, das dificuldades práticas da instalação e da representatividade do estande pode ser problemática. Para a maioria dos experimentos, 4 a 6 repetições é um número bastante razoável.

Por outro lado, o número de repetições pode depender do parâmetro a estimar. Para estudos de genética quantitativa, o número de repetições pode ser bem maior. Estimadores do componentes de variância, por exemplo, possuem variância proporcional ao quadrado do próprio valor; exigindo para confiabilidade maiores graus de liberdade associados, o que pode ser conseguido pelo adequado dimensionamento do número de repetições. Representação da

variabilidade genética natural ou em progêneres de uma família também são exemplos em que o número de repetições ou de indivíduos deve ser maior ( Resende, 2002).

### **7.5) Delineamentos de tratamentos**

No sentido amplo, o termo delineamento pode ser entendido como “forma de dispor” ou “de arranjar”. Portanto temos o delineamento experimental que é a forma de dispor as parcelas no campo, que acabamos de discutir e temos ainda o delineamento de tratamentos que é a forma de dispor os tratamentos.

Os tratamentos podem ser dispostos nas formas:

1. **Um fator, com níveis ou valores qualitativos.** Os tratamentos não podem ser ordenados segundo um critério numérico, mas diferem por qualidades. Podem ser variedades, marcas, processos, etc. Ex: experimentos de competição de variedades ou cultigares de culturas. Modelo usual de análise: uma média para cada nível do fator.
2. **Um fator, com níveis quantitativos.** Os tratamentos representam valores ordenáveis, como por exemplo, doses, espaçamentos, densidades, tempo, distâncias, etc. Para esses casos, o modelo usual de análise: uma curva de respostas em função da dose (análise de regressão).
3. **Mais de um fator ou experimentos fatoriais.** Um experimento é denominado factorial quando dois ou mais fatores são combinados simultaneamente, na mesma parcela. Cada fator é composto pelos chamados níveis do fator e as combinações entre os níveis dos fatores formam os tratamentos do experimento factorial.

Vejamos alguns exemplos de fatores e respectivos níveis:

<b>FATOR</b>	<b>NÍVEIS</b>
Doses de NPK	0; 100; 200; 300 ... kg/ha
Épocas de plantio	Inverno, primavera, outono e verão
Raça	Raça 1; Raça 2; ... Raça 10
Ração	Granulada, farelada

Os experimentos fatoriais são utilizados com freqüência e podem ser instalados em qualquer um dos delineamentos experimentais. Existem técnicas especiais para análise dos efeitos dos fatores e de suas interações.

Podemos, então, denominar o factorial de acordo com o número de fatores:

- a) Bifatorial – quando são avaliados dois fatores em diferentes níveis cada um;

- b) Trifatorial – quando são avaliados três fatores em diferentes níveis cada um;

Por exemplo, dois fatores, com 2 níveis do fator A e 3 níveis do fator B, temos  $2 \times 3 = 6$  tratamentos. Se, casualizados segundo o DIC com 3 repetições (18 parcelas), resulta:

F <sub>2</sub> P <sub>1</sub>	F <sub>2</sub> P <sub>2</sub>	F <sub>1</sub> P <sub>1</sub>	F <sub>2</sub> P <sub>3</sub>	F <sub>1</sub> P <sub>2</sub>	F <sub>2</sub> P <sub>3</sub>	F <sub>2</sub> P <sub>1</sub>	F <sub>2</sub> P <sub>2</sub>	F <sub>1</sub> P <sub>2</sub>
F <sub>1</sub> P <sub>3</sub>	F <sub>1</sub> P <sub>2</sub>	F <sub>2</sub> P <sub>3</sub>	F <sub>2</sub> P <sub>1</sub>	F <sub>2</sub> P <sub>2</sub>	F <sub>1</sub> P <sub>3</sub>	F <sub>1</sub> P <sub>1</sub>	F <sub>1</sub> P <sub>3</sub>	F <sub>1</sub> P <sub>1</sub>

De forma resumida, os fatores podem ter níveis qualitativos ou quantitativos, ser cruzados ou aninhados; fixos (previamente escolhidos) ou aleatórios (amostra dos possíveis) . Na medida do possível, alguns exemplos serão apresentados ou discutidos nas aulas.

## 8. EXPERIMENTOS FATORIAIS

Como visto nesta apostila, um experimento é denominado fatorial quando duas ou mais séries de tratamentos (fatores) são combinados simultaneamente, no mesmo experimento. Na prática os tratamentos são formados por combinações de níveis de mais de um fator. Uma característica fundamental no estudo dos experimentos fatoriais e que pode ocorrer quando se combinam fatores são as interações. As interações podem ser benéficas ou maléficas e alteram as respostas em relação ao efeito isolado de cada fator. Assim, teremos os efeitos principais que são os efeitos dos níveis dos fatores e os efeitos de interações entre os fatores.

Com 2 fatores (por exemplo, ADUBO e MANEJO), teremos os efeitos principais, no caso de ADUBO e de MANEJO, e também as interações ADUBO X MANEJO ..

Consideremos um exemplo com 2 níveis (presença e ausência) de adubação mineral e 2 manejos (presença e ausência) de torta de filtro de usinas de açúcar na produção das parcelas de cana-de-açúcar. Os dados de produção são apresentados na Tabela a seguir (kg/parcela):

Tratamentos					
Bloco	(1)	Adubo (A)	Manejo (M)	A+M	Total
1	18,0	20,6	19,6	19,2	77,4
2	8,6	21,0	15,0	19,6	64,2
3	9,4	18,6	14,6	18,4	61,0
4	11,4	20,6	15,8	20,2	68,0
Total	47,4	80,8	65,0	77,4	270,6

(1) Sem adubo e sem torta

A partir dos dados temos a seguinte Tabela de análise de variância:

F V	GL	SQ	QM	F	Pr > F
Bloco	3	37,8275	12,6091	3,0099	0,08680
Adubo	1	131,1025	131,1025	31,2956	<b>0,00056</b>
Manejo Torta	1	12,6025	12,6025	3,0084	0,11437
Adubo x manejo	1	27,5625	27,5625	6,5795	<b>0,02924</b>
Resíduo	9	37,7024	4,1891		
Total	15	246,7974			

Média geral = 16,91; CV= 12,10%

Como podemos observar na Tabela de análise de variância a interação Adubo x Manejo é significativa ao nível de 5% de probabilidade ((Pr > F)<0,05). O efeito principal do Adubo mineral é significativo a 1%, no entanto o efeito do manejo é não significativo.

A interação Adubo x Manejo pode ser estimada com os totais obtidos para cada tratamento, a partir de uma tabela de dupla entrada:

(4)	M <sub>0</sub>	M <sub>1</sub>	Totais
A <sub>0</sub>	47,4	65,0	112,4
A <sub>1</sub>	80,8	77,4	158,2
Totais	128,2	142,4	270,6

Então, a interação pode ser estimada assim:

$$A \times M = (A_0 M_0 + A_1 M_1) - (A_0 M_1 + A_1 M_0) / 2 \cdot 4$$

$$A \times M = ((1) + AM - A - M) / 8$$

$$A \times M = (47,7 + 77,4 - 80,8 - 65,0) / 8 = -2,625$$

O termo 4 é usado porque cada total da Tabela é soma das produções de 4 parcelas.

Com essa estimativa podemos verificar que a interação Adubo X Manejo, significativa a 5% de probabilidade, é negativa, pois a soma dos termos da diagonal principal é menor que os da diagonal secundária. Isoladamente, tanto a manejo, como o adubo, manifestam seus efeitos, mas quando juntos os efeitos não se somam e é por isso que a interação é negativa.

Tendo o resultado da interação significativa é possível fazer uma outra análise de variância, considerando o desdobramento dessa interação em “cortes”, ou seja, considerando os níveis de um fator isoladamente em cada nível do outro fator.

Então a estrutura da nova análise de variância é:

FV	GL	SQ	QM	F	Pr > F
Bloco	3	37,8275	12,6091	3,009	0,0868
Adubo	1	131,1025	131,1025	31,295	<b>0,0005</b>
Manejo com Adubo0	1	38,7200	38,7200	9,242	<b>0,0136</b>
Manejo com Adubo1	1	1,4449	1,4449	0,344	0,5766
Manejo com Adubo 0+1	2	40,1650	20,0825	4,793	0,0543
Resíduo	9	37,7024	4,1891		
Total	15	246,7975			

Média geral = 16,91; CV = 12,10%

Nessa última análise podemos observar que o manejo mostrou efeito significativo apenas na ausência de adubo (adubo0), ou seja, ela mostrou efeito substitutivo (não independência). Nota-se que  $SQ_{(\text{Manejo com Adubo 0 + 1})} = SQ_{(\text{Manejo})} + SQ_{(\text{Adubo x Manejo})}$ .

### Interação entre fatores

Uma das principais informações em experimentos fatoriais é a da interação entre os fatores, ou seja, verificar se as diferenças nas respostas dos níveis de um fator são similares ou diferentes em cada um dos níveis do (s) outro (s) fator (es). As interações são efeitos adicionais positivos (sinergismo) ou negativos (antagonismo) que aparecem quando se combinam níveis de dois ou mais fatores. No entanto, nem sempre é fácil de detectar ou analisar completamente os efeitos de interações.

Seja, por exemplo, um experimento fatorial A x B, com níveis m e n, respectivamente, para os fatores A e B, e para simplificar com r repetições. Nesse caso, a interação tem  $(m-1)(n-1)$  graus de liberdade. Quando se faz análise de variância “rotineira”, a estatística F serve para testar a interação média ou “pooled”. Pode-se dizer que é um teste da interação “por experimento”.

Há várias situações possíveis:

- 1) Interação significativa do tipo simples: As respostas de um fator não são similares para todos os níveis do outro fator: A interpretação pode ser obtida com ‘cortes’ da resposta de

um fator para cada nível do outro fator. É um procedimento muito usual e eficaz para essa situação, detectando em quais ‘cortes’ ocorrem respostas diferentes que promovem interações significativas. O procedimento é frequentemente denominado análise com desdobramento dos graus de liberdade.

2) Interação “quase significativa” do tipo simples: Mesmo nesse caso pode ser interessante examinar as interações mais detalhadamente. Podem ser construídos testes para examinar efeitos “por comparação”. É uma situação com implicações teóricas similares as que ocorrem em outras áreas da estatística: Testes de coeficientes de regressão múltipla, procedimentos de comparações múltiplas, etc. Há taxas de erros associadas as interações do experimento como um todo e as associadas às comparações (O'Neill & Wetherill, 1971).

Algumas comparações podem ser muito mais importantes que outras..

3) Interação significativa do tipo complexa: Diferentemente dos casos anteriores, as respostas responsáveis pelas interações não estão fortemente associadas a níveis de qualquer dos fatores. Há  $m \times n$  combinações ou tratamentos e as interações são devidas a tratamentos específicas. Para esses casos, a análise com auxílio de ‘cortes’ é pouco efetiva e a alternativa é avaliar todas “caselas” ou tratamentos, na tentativa de detectar melhores ou piores combinações dos níveis dos fatores. Essa situação é ilustrada no exemplo 2.

**Exemplo 1:** Um experimento fatorial (3x3) foi realizado pela Dra Leila L. Dinardo-Miranda do Centro de Cana IAC visando avaliar a produtividade de cana-de-açúcar (kg /parcela) submetida a três doses de um produto para controle praga de solo, em três épocas de aplicação. O experimento foi delineado em blocos ao acaso com seis repetições e com nove parcelas cada bloco. Resumo da análise de variância está nas Tabela 1 e 2.

A interação “por experimento” época x dose é significativa só a 8,62% ( $p = 0,0862$ , Tabela 3). Supondo o nível de significância de 5%, comumente utilizado em análises de variância, evidenciaria que o efeito de interação é nulo. Interpretando dessa forma, a verificação da significância de efeitos principais de época e dose é um procedimento adequado, e neste caso evidencia efeito significativo somente de época de aplicação ( $p =$

0,0104). Ao desdobrar a interação época x dose, efeito significativo de doses dentro de época 1 ( $p = 0,0084$ ) é visualizado. Portanto, se a análise não for explorada “por comparações”, informações valiosas podem ser perdidas.

A significância do efeito de doses, somente na época 1, comprova uma hipótese inicial, fundamentada na forma sistêmica de ação do produto, ou seja, os efeitos de doses só se manifestam se o produto for aplicado na primeira época (início de desenvolvimento da cultura).

Este exemplo, entre tantos outros, demonstra a importância de observar efeitos da interação “por comparações” e não somente “por experimento”. Embora seja um assunto pouco discutido em textos de análise de experimentos, alguma informação suplementar pode ser obtida em Bancroft (1968). Perecin & Cargnelutti (2008) sugerem que o pesquisador seja mais tolerante com a taxa de erro “por experimento” (que é um teste para a interação média), aceitando nível de significância, por exemplo de 25% , para poder detectar efeitos importantes de interações “por comparações”, agora neste item aceitando significância, por exemplo de 5%.

**Exemplo 2:** Em experimentos de adubação de plantas, as respostas podem estar associadas aos balanceamentos entre os nutrientes ou ao nutriente no mínimo, regidos pela famosa Lei de Liebig (Kreuz et al., 1995), podendo então originar interações do tipo complexa. Para ilustrar, considere os dados das Tabelas 3 e 4 de um exemplo da produção de cana-de-açúcar em função de nitrogênio (N) e fósforo (P), adaptado de Gomes ( 2000).

A interação Nitrogênio x Fósforo é fortemente significativa ( $p = 0,0094$ ), mas os “cortes” apresentados na Tabela 3 são pouco informativos. Somente os efeitos de N dentro das doses zero P0 (ausência) e P2 são não significativos ( $p > 0,05$ ). Análises de comparações selecionadas, superfícies de respostas ou mesmo comparações múltiplas com todas as médias podem ser mais eficientes. A análise com comparações múltiplas (Tukey 5%, Tabela 4) sugere que há um platô nas doses (1 e 1), (1 e 2), (2 e 1) e (2 e 2) de N e P, respectivamente. Ou seja, as doses 1 de N e 1 de P provavelmente são satisfatórias. A

resposta na dose 2 de P na ausência de N contribui fortemente para a complexidade da interação. Embora estranha, pode ser parcialmente explicada pelas funções do fósforo, com estímulo ao desenvolvimento inicial do sistema radicular e ampliação da zona de exploração, alterando o balanço dos nutrientes no solo. Esse exemplo dá uma idéia da complexidade das interações e sugerem que comparações entre tratamentos ou "caselas" podem auxiliar na sua interpretação.

Tabela 1. Análise de variância em relação à produtividade de cana-de-açúcar (kg/parcela) e desdobramento da interação Época x Dose.

Fontes de Variação	GL	Quadrado Médio	F	Pr > F
BLOCO	5	8.294,1	1,61	0,1806
ÉPOCA	2	26.496,3	5,13	0,0104
DOSE	2	7.314,4	1,42	0,2545
ÉPOCA*DOSE	4	11.365,7	2,20	0,0862
Doses dentro Época 1	2	27.839,0	5,39	0,0084
Doses dentro Época 2	2	372,2	0,07	0,9306
Doses dentro Época 3	2	1.834,7	0,35	0,7031
RESÍDUO	40	5.163,5		

Fonte: Centro de Cana IAC

Tabela 2. Média da produtividade de cana-de-açúcar (kg/parcela) em cada época e dose de um produto para controle praga de solo.

	Dose 1	Dose 2	Dose 3
Época 1	658,3 b	710,0 ab	793,3 a
Época 2	710,0 a	706,7 a	721,7 a
Época 3	656,7 a	664,2 a	630,8 a

Fonte: Centro de Cana IAC. Dms (Tukey 5%) = 100,9 kg/parcela. Médias não seguidas de mesma letra minúscula na linha diferem entre si ao nível de 5% de probabilidade.

Tabela 3. Análise de variância da produção de cana-de-açúcar (dados em toneladas por hectare, extraído de Gomes, 2000).

Fontes de Variação	GL	Quadrado Médio	F	Pr > F
Nitrogênio (N)	2	21,6	0,34	0,7148
Fósforo (P)	2	2.625,7	42,06	0,0000
Nitrogênio x Fósforo	4	267,3	4,28	0,0094
1) Cortes para níveis de P				
Nitrogênio dentro de P0	2	49,7	0,80	0,4628
Nitrogênio dentro de P1	2	342,1	5,48	0,0110
Nitrogênio dentro de P2	2	164,1	2,63	0,0928
2) Cortes para níveis de N				
Fósforo dentro de N0	2	1.427,2	22,86	0,0000
Fósforo dentro de N1	2	1.131,0	18,12	0,0000
Fósforo dentro de N2	2	602,1	9,64	0,0008
Resíduo	24	62,4		

Fonte: Adaptado de Gomes (2000)

Tabela 4. Média da produtividade de cana-de-açúcar (t/ha) de 6 parcelas para cada combinação das doses de nitrogênio (N) e de fósforo (P), toneladas de por hectare, dados extraídos de Gomes (2000).

	Dose 0 de N	Dose 1 de N	Dose 2 de N
Dose 0 de P	36,4 c	33,7 c	39,5 c
Dose 1 de P	44,2 bc	57,9 ab	56,5 ab
Dose 2 de P	66,1 a	57,0 ab	57,1 ab

Fonte: Adaptado de Gomes (2000).

Erro padrão das médias = 3,2 t /ha. Dms (Tukey 5%) = 15,7 t/ ha

## 9. ANÁLISES CONJUNTAS DE EXPERIMENTOS

Nos experimentos de avaliação de cultivares ou de recomendações de algumas práticas culturais é fundamental que os experimentos sejam repetidos em vários locais e vários anos.

A análise conjunta é interessante para avaliar as interações com ambientes (locais ou anos) e também para verificar os efeitos gerais, quando presentes.

Para realizar a análise conjunta há necessidade de certa homogeneidade das variações ambientais, pois a análise conjunta no geral é feita com a média dessas variações.

Na prática, isso é avaliado pela grandeza dos quadrados médios residuais, que amostram as variâncias ambientais. Gomes (2000), compilando vários estudos sugerem que a relação entre o maior e o menor quadrado médio do resíduo deva ser menor que 7.

Sabe-se de longa data que os materiais biológicos interagem com o ambiente e isso pode resultar respostas diferentes do fenótipo observado em cada local.

Do ponto de vista do melhoramento, interessam materiais robustos quanto a pequenas variações do ambiente. Por essa razão, os experimentos devem ser repetidos em vários ambientes e em vários anos, para que haja condição efetiva de manifestação dos efeitos e avaliação dos materiais.

Os experimentos devem ser conduzidos com muito cuidado em todos locais. Sendo muito usual fazer inicialmente uma análise conjunta, que será discutida em item adiante.

Do ponto de vista teórico, admitindo-se que as respostas ( $Y$ ) e os ambientes ( $X$ ) possuem distribuições normais (binormais), demonstra-se que a função que relaciona o valor esperado de  $Y$  para cada  $X$  conhecido é uma reta. Isso é um teorema clássico em probabilidade.

Na aplicação prática desse teorema, uma dificuldade é medir o ambiente ( $X$ ). Uma idéia, atribuída a Eberhart e Russel (1966), é tomar uma amostra de ambientes e definir  $X$  como a diferença entre o  $Y$  médio de cada local e o  $Y$  médio geral. Originam-se assim os ambientes bons (acima da média geral) e os ambientes ruins (abaixo da média geral). Se a regressão linear simples (reta) explicar as respostas médias  $Y$  em função do índice de ambiente  $X$ , é dito que o genótipo tem plasticidade ou adaptabilidade aos ambientes. Um defeito desse método é que  $X$  é função direta do próprio  $Y$  e defeito agrava-se se os ambientes e/ou os genótipos não forem escolhidos de forma aleatória, o que é muito comum. Há, então, diversas outras maneiras de analisar as interações do genótipo com o ambiente (Crossa, 1990).

Experimentos de competição de cultivares (ou testes clonais) são fundamentais para avaliar as qualidades de novos materiais genéticos, pois são desses experimentos que podem surgir recomendações para lançamentos de variedades. A expectativa é que o novo material seja melhor que o antigo, envolvendo, então enormes responsabilidades.

Os lançamentos devem ser precedidos de experimentos ou ensaios regionais e estaduais e, para esses, há necessidade de cuidados especiais para que se possam tirar conclusões com segurança. Eles devem ser conduzidos em vários locais e preferencialmente em vários anos. As análises podem ser feitas por procedimentos clássicos da análise de variância ou por modelos mistos e procedimentos ótimos (Resende, 2002).

A questão fundamental nos experimentos é que se controle a uniformidade e para isso os experimentos devem ser bem conduzidos e a amostra de cada parcela deve ser adequada para que os materiais manifestem seus verdadeiros valores.

Uma interessante maneira de avaliar a uniformidade do experimento é através do coeficiente de variação, definido como o quociente porcentual entre o desvio padrão e a média do experimento.

O desvio padrão é uma medida internacionalmente usada, da variabilidade entre repetições do mesmo material e depende da maneira criteriosa de conduzir o experimento e amostrá-lo. Serve para avaliar indiretamente se o experimento foi bem conduzido e se as respostas foram boas.

Para chamar atenção, na Tabela 5 são mostrados os DMS (diferença mínima significativa, no caso, T 5%) necessários para que um material possa ser considerado superior a outro em termos de produção (t/ha), a partir de experimentos conduzidos em blocos casualizados com 4 repetições.

A fórmula de forma descritiva é :

$$\text{DMS} = \text{Valor tabelado} \times \text{Média geral} \times (\text{CV}/100)/(\text{raiz quadrada do nº de repetições}).$$

Nota-se pela fórmula e pela Tabela 5, a conveniência de se trabalhar com CV baixos (preferencialmente menores que 5%); caso contrário, fica muito difícil concluir se a diferença observada é realmente de superioridade ou de simples acaso.

Por exemplo, para um CV de 15%, a Tabela 5 mostra que só se provará a superioridade de um clone se no experimento apresentar uma diferença superior a 15 t/ha;

se estiver em apenas um ambiente! Mas isso baixa para menos de 3 t/ha, se o CV for de 5% e estiver em 5 ambientes.

Portanto, ficam claros os benefícios da repetição em vários ambientes, especialmente se não ocorrer forte interação (genótipo x ambiente). Demonstra-se que entre aumentar repetições num só ambiente ou aumentar o número de ambientes, a segunda alternativa é mais eficiente.

**TABELA 5** - Diferença mínima significativa pelo T 5% (LSD) para comparar produção de clones ou variedades de cana-de-açúcar, em t/ha, em função do coeficiente de variação (CV), para 10 genótipos em 1 e 5 ambientes e da produção média do experimento, em blocos casualizados com 4 repetições.

Coef. Variação	10 clones em 1 só ambiente			10 clones em 5 ambientes		
	70 t/ha	80 t/ha	90 t/ha	70 t/ha	80 t/ha	90 t/ha
2 %	2,0	2,3	2,6	0,9	1,0	1,1
5 %	5,0	5,7	6,4	2,1	2,5	2,8
10 %	10,0	11,4	12,9	4,3	4,9	5,5
15%	15,0	17,1	19,3	6,4	7,4	8,3
20 %	20,0	22,9	25,3	8,6	9,8	11,0

A questão fundamental nos experimentos é que se controle a uniformidade e para isso os experimentos devem ser bem conduzidos e a amostra de cada parcela deve ser adequada para que os tratamentos (raças, linhagens, práticas de manejo etc) manifestem seus verdadeiros valores.

Para realizar a análise conjunta há necessidade de certa homogeneidade das variações ambientais, pois a análise conjunta no geral é feita com a média dessas variações.

Na prática, isso é avaliado pela grandeza dos quadrados médios residuais, que amostram as variâncias ambientais. Gomes (2000), compilando vários estudos sugerem que a relação entre o maior e o menor quadrado médio do resíduo deva ser menor que 7.

Perecin (2008) mostra que as relações dependem do grau de liberdade associado aos experimentos individuais em cada local ou ano e valores até 10 podem ser aceitáveis quando os graus de liberdade do resíduo dos experimentos individuais estão ao redor de 10. Para maiores graus de liberdade do resíduo, as relações devem ser menores.

Portanto, dependendo do grau de liberdade associado o valor 7 pode ser alterado, para valores mais apropriados à confiança estabelecida.

**Exemplo:** Seja um experimento para testar ganho de peso mensal de filhos (progêneres) de tourinhos novos (A, B, C e D) e um touro testemunha em quatro locais. Supor DIC em cada local com 4 repetições (filhos diferentes), com as seguintes TOTAIS e análise estatística:

Touros	Local 1	Local 2	Local 3	Local 4
A	12,6	39,5	26,5	27,4
B	10,8	36,5	29,0	29,0
C	10,8	40,0	26,5	26,2
D	11,8	42,5	33,5	28,0
Testemunha	9,4	33,5	24,5	17,4
Anova:				
GLResíduo	15	15	15	15
QMResíduo	0,50	1,12	1,53	2,23
Fc	0,73ns	2,70ns	1,96ns	2,47ns
Ft (5%)	3,06	3,06	3,06	3,06

Pelos resultados em cada local, não são obtidas diferenças significativas, mas note que a testemunha é menor em todos locais.

No caso, a relação entre o maior e o menor QMResíduo é menor que 7 e a análise conjunta pode ser feita, gerando informações interessantes.

Fontes de Variação	GL	QM	F	Ft (5%)
LOCAIS (L)	3	158,47	110,82*	2,76
TOUROS (T)	4	7,96	5,57*	2,53
INTERAÇÃO: LxT	12	1,31	0,98ns	1,92
RESÍDUO Dentro de LOCAIS	60	1,43		

Notem que não há interação significativa, ou seja, os efeitos de Touros se manifestam de forma independente do local e as médias são:

$$mA = 6,62a$$

$$mB = 6,58a$$

$$mC = 6,47a$$

$$mD = 7,23a$$

$$mTest = 5,30b$$

Fazendo HSD (Tukey 5%) =  $3,98^* (1,34/16)1/2 = 1,15$  e avaliando as médias, conclui-se que os touros novos (A, B,C e D) produzem filhos com pesos similares e maiores que o touro testemunha.

## **Interação tratamento x local**

Quando a interação é significativa há necessidade de avaliar mais detalhadamente os experimentos por locais. Uma causa muito frequente são interações genótipo x ambiente (GxE), muito comuns em experimentos biológicos.

Sabe-se de longa data que os materiais biológicos interagem com o ambiente e isso pode resultar respostas diferentes do fenótipo observado em cada local.

Do ponto de vista do melhoramento, interessam genótipos (animais ou vegetais) robustos quanto a pequenas variações do ambiente. Por essa razão, os experimentos devem ser repetidos em vários ambientes e em vários anos, para que haja condição efetiva de manifestação dos efeitos e avaliação dos genótipos ou de tratamentos aplicados a eles.

Os experimentos devem ser conduzidos com muito cuidado em todos locais. Sendo muito usual fazer inicialmente uma análise conjunta.

## **Análise conjunta de experimentos pequenos**

No geral experimentos em que o grau de liberdade do resíduo é pequeno (menor que 10) não permitem conclusões efetivas e é preciso repetir o experimento para que as conclusões tornem-se válidas.

Na experimentação com animais (vacas leiteiras, cavalos, animais fistulados, gatos, cães etc) é comum se ter poucos animais e um recurso é fazer quadrados latinos em que nas linhas são colocados os animais e nas colunas os períodos sucessivos. Assim cada animal recebe todos tratamentos, em períodos sucessivos e , em todos períodos, há todos os tratamentos..Nesse sentido é muito comum usar quadrados latinos (3x3 ou 4x4), repetido várias vezes.

Se os experimentos pequenos forem repetidos no mesmo ambiente, não se espera interação GxE. A relação entre o maior e menor quadrado médio do resíduo, nesse caso pode, por simples acaso, ser maior que 10 (Perecin, 2008) e isso, em princípio, não impede que se faça a análise conjunta.

**Exemplo:** Para estudar a degradação(dados em % de degradação) de quatro forrageiras foram usados oito animais fistulados em dois quadrados latinos (4x4) , com os resultados a seguir.

### Experimento 1 ou quadrado latino 1

	Período 1	Período 2	Período 3	Período 4
Animal 1	A (=50)	B (=62)	C (=80)	D (=87)
Animal 2	B (=60)	C (=75)	D (=90)	A (=58)
Animal 3	C (=70)	D (=80)	A (=53)	B (=65)
Animal 4	D (=75)	A (=52)	B (=64)	C (=75)

OBS: Degradação de cada forrageira dentro dos parênteses.

Anova:

Fontes de Variação	Graus de Liberdade	Soma de Quadrados	Quadrado Médio
Animal	3	51,5	
Período	3	169,0	
Forrageira	3	2072,5	
Resíduo	6	17,0	2,83
Total	15		

### Experimento 2 ou quadrado latino 2 (ou repetição em outra época do anterior)

	Período 5	Período 6	Período 7	Período 8
Animal 5	A (=55)	B (=68)	C (=70)	D (=85)
Animal 6	B (=64)	C (=75)	D (=80)	A (=59)
Animal 7	C (=72)	D (=90)	A (=50)	B (=70)
Animal 8	D (=90)	A (=51)	B (=60)	C (=80)

## Anova

Fontes de Variação	Graus de Liberdade	Soma de Quadrados	Quadrado Médio
Animal	3	3,2	
Período	3	153,2	
Forrageira	3	2265,7	
Resíduo	6	78,9	13,15
Total	15		

## Análise conjunta

Fontes de Variação	GL	SQ	QM	F	Ft(5%)
Experimento ou QL	1	16,53	16,53		
Animal dentro QL	3+3	54,69	9,11		
Período dentro QL	3+3	322,19	53,69		
Forrageiras (For)	3	4316,84	1438,95	180,1*	3,49
Interação QLxFor	3	21,34	7,11	0,89ns	3,49
Resíduo dentro QL	6+6	95,9	7,99		
Total	31				

### Médias de degradação

Forrageira A =  $(50 + 58 + 53 + 52 + 55 + 59 + 50 + 51) / 8 = 53,5d$

Forrageira B=74,6b

Forrageira C =64,1c

Forrageira D =84,6a

Dms (HSD)=4,2

**Conclusão:** Todas forrageiras degradam de forma estatisticamente diferentes, sendo A que menos degrada e D a que mais degrada.

## 10. REFERÊNCIAS BÁSICAS

- BANCROFT, T.A. **Topics in intermediate statistical methods.** Ames, IOWA, The State University Press. V.1, 1968.129p.
- BANZATTO, D. A. e KRONKA, S. N. **Experimentação agrícola.** Jaboticabal: FUNEP, 1989. 247 p.
- BUSSAB, W. O. e MORETTIN, P. A. **Estatística Básica.** 5.ed. São Paulo: Editora Saraiva, 2002. 540p.
- CAMPOS, H. **Estatística aplicada à experimentação com cana-de-açúcar.** Piracicaba, FEALQ/PLANALSUCAR, 1984. 292p.
- CROSSA, J. Statistical analysis of multilocation trials. Advances Agronomy, v. 44, p.55-85, 1990
- EBERHART, S. A. ; RUSSEL, W. A. Stability parameters for comparing varieties. Crop Sci., v.6, p.36-40, 1966.
- GOMES, F. P. e GARCIA, C. H. **Estatística aplicada a experimentos agronômicos e florestais.** Piracicaba: FEALQ, 2002. 309 p.
- GOMES, F. P. **Curso de Estatística Experimental.** 14. ed., Piracicaba, ESALQ/USP, 2000. 477p.
- KALIL Apostila sobre experimentação com animais . 1974.
- KREUZ, C.L.; LANZER, E.A.; PARIS, Q. Funções de produção Von Liebig com rendimentos decrescentes. Pesquisa Agropecuária Brasileira, v.30, p.95-106, 1995.
- MORETTIN, L. G. **Estatística Básica (Probabilidade). Volume I.** 7. ed., São Paulo: Makron Books, 2003. 230p.
- O'NEILL, R. ; WETHERILL, G.B. The present state of multiple comparison methods. J. Royal Stat. Soc., B ,v.33, p.218-250, 1971.
- PERECIN, D. Experimentação com cana-de-açúcar. IN: DINARDO-MIRANDA, L. L.,VASCONCELOS, A. C. M. & LANDEL, M.G. A. Cana-de-açúcar. Campinas, IAC, 2008, p.809-820
- PERECIN, D. ; BARBOSA, J.C. Uma avaliação de seis procedimentos para comparações múltiplas. Rev. Mat. Estat., São Paulo, v.6, p.95-103, 1988.
- PERECIN, D. ; MALHEIROS, E.B. Procedimentos para comparações múltiplas.

Lavras-MG, Rbras, 1989. 67p (minicurso SEAGRO).

PERECIN, D.; CARGNELUTTI Fº, A. Efeitos por comparações e por experimento em interações de experimentos fatoriais. Ciência e Agrotecnologia, v. 32, p.68-72, 2008.

REZENDE, M. D. V. Genética biométrica e estatística no melhoramento de plantas perenes. Brasília, Embrapa. 2002. 975p.

SAMPAIO, I. B. M. **Estatística aplicada à experimentação animal.** 3 ed., Belo Horizonte, Fundação de Estudo e Pesquisa em Medicina Veterinária e Zootecnia, 2007. 264p.

SCOTT, R. A. ; MILLIKEN, G. A SAS program for analysing augmented randomized complete-block designs. Crop Science, v. 33, p.865-867,1993.

STORCK, L.; GARCIA, D.C.; LOPES, S.J.; ESTEFANEL, V. **Experimentação vegetal.** 2 ed., Santa Maria: UFSM, 2006. 198p.

VIEIRA, S. **Estatística Experimental.** 2. ed., São Paulo, Atlas, 1999. 185p.

## 11. ANEXOS

### 1) ANEXO 1: CONTRASTES

Teoricamente, os procedimentos de comparações múltiplas (t, Tukey e outros) são corretos quando não há pré-suposição a respeito dos tratamentos. Todos, em princípio, podem ser iguais e não comparações preferenciais. São então feitas todas as comparações 2 a 2, tentando decifrar o que diferencia os tratamentos (O'Neill & Wetherill, 1971).

Contrastes são muito úteis para avaliar comparações direcionadas ou estruturadas. Ou seja, a priori há alguma estruturação nos tratamentos , de modo que certas comparações, preferencialmente independentes (ortogonais), são mais informativas e facilitam a interpretação do experimento.

Definição de contraste entre médias de tratamentos:

Sejam  $t$  estimadores das médias ( $m_1, m_2, \dots, m_t$ ) de  $n$  tratamentos:

$C = c_1m_1 + c_2m_2 + \dots + c_tm_t$  é uma função linear das médias e se a soma dos coeficientes ( $c_1 + c_2 + \dots + c_t = 0$ ),  $C$  é denominado contraste entre as médias.

A variância de um contraste, supondo independência dos tratamentos, é :  
 $V(C) = \sum c_i V(m_i)$ .

No caso da análise de variância, com independência e homogeneidade da variância dentro dos tratamentos,  $V(m_i)$  é estimada por QMRES/rep, onde QMRES= quadrado médio do resíduo e rep= número de repetições.

A soma de quadrados de um contraste, com um grau de liberdade, é obtida por:

$SQ = (\sum c_i T_i)^2 / (\sum c_i^2 \cdot rep)$ , onde  $T_i$  é o total do tratamento  $i$ .

Dois contrastes são independentes se a covariância entre eles for nula.

Se as variâncias e o número de repetições forem todos iguais, a condição de independência torna-se igual a condição de ortogonalidade entre matrizes:

$$\sum a_i = \sum b_i = 0$$

$$\sum a_i \cdot b_i = 0$$

**Exemplo:** Seja um experimento hipotético com 4 tratamentos e 3 repetições, em DIC, com os seguintes totais:  $T1=15$ ,  $T2=18$ ,  $T3=21$ ,  $T4=30$  e somas de quadrados  $SQ_{Tratamentos}=42$  e  $SQ_{RES}=24$ .

**Caso hipotético 1:** T1 e T2 são sulfas (S1 e S2) e T3 e T4 são antibióticos.  
Uma análise de variância interessante, com três contrastes ortogonais, é :

FONTES DE VARIAÇÃO	c <sub>1</sub>	c <sub>2</sub>	c <sub>3</sub>	c <sub>4</sub>	GL	SQ	R <sup>2</sup>
C1: Sulfas versus Antibióticos	-1	-1	1	1	1	27,0	64,3
C2: Entre sulfas	-1	1	0	0	1	1,5	3,6
C3: Entre antibióticos	0	0	-1	1	1	13,5	32,1
Resíduo					8	24	

Obs: c<sub>i</sub> coeficientes dos contrastes, GL=grau de liberdade, SQ=soma de quadrados, R<sup>2</sup> = porcentagem da soma de quadrados de tratamentos =42. Os valores de R<sup>2</sup> mostram a importância relativa de cada contraste.  
Nesse caso, a maior diferença está em C1, seguido de C3.

**Caso hipotético 2:** T1 é placebo, T2 e T3 são sulfas (S1 e S2) e T4 é um antibiótico.

Uma análise de variância interessante, com três contrastes ortogonais, é :

FONTES DE VARIAÇÃO	c <sub>1</sub>	c <sub>2</sub>	c <sub>3</sub>	c <sub>4</sub>	GL	SQ	R <sup>2</sup>
C1: Placebo versus Demais	-3	1	1	1	1	16,0	38,1
C2: Sulfas versus Antibióticos	0	-1	-1	2	1	24,5	58,3
C3: Entre Sulfas	0	-1	1	0	1	1,5	1,5
Resíduo					8	24	

Obs: c<sub>i</sub> coeficientes dos contrastes, GL=grau de liberdade, SQ=soma de quadrados, R<sup>2</sup> = porcentagem da soma de quadrados de tratamentos =42. Os valores de R<sup>2</sup> mostram a importância relativa de cada contraste.

**Caso hipotético 3:** Os tratamentos são combinações fatoriais de dois produtos(A e B) , em duas doses (1 e 2): T1 =a1b1, T2=a1b2, T3=a2b1 e T4= a2b2.

Uma análise de variância interessante, com três contrastes ortogonais, é :

FONTES DE VARIAÇÃO	c <sub>1</sub>	c <sub>2</sub>	c <sub>3</sub>	c <sub>4</sub>	GL	SQ	R <sup>2</sup>
C1: Fator A	-1	-1	1	1	1	27,0	64,3
C2: Fator B	-1	1	-1	1	1	12,0	28,6
C3: Interação: AxB	1	-1	-1	1	1	3,0	7,1
Resíduo					8	24	

Obs: c<sub>i</sub> coeficientes dos contrastes, GL=grau de liberdade, SQ=soma de quadrados, R<sup>2</sup> = porcentagem da soma de quadrados de tratamentos =42. Os valores de R<sup>2</sup> mostram a importância relativa de cada contraste.

**Caso hipotético 4:** T1 , T2, T3 e T4 são doses eqüidistantes de um antibiótico. Uma análise de variância interessante, com três contrastes ortogonais, é :

FONTES DE VARIAÇÃO	c <sub>1</sub>	c <sub>2</sub>	c <sub>3</sub>	c <sub>4</sub>	GL	SQ	R <sup>2</sup>
C1: Efeito linear	-3	-1	1	3	1	38,4	91,4
C2: Quadrático após linear	1	-1	-1	2	1	3,0	7,1
C3: Cúbico após C1 e C2	-1	3	-3	1	1	0,6	1,4
Resíduo					8	24	

Obs: c<sub>i</sub> coeficientes dos contrastes, GL=grau de liberdade, SQ=soma de quadrados, R<sup>2</sup> = porcentagem da soma de quadrados de tratamentos =42.

Os valores de R<sup>2</sup> mostram a importância relativa de cada contraste.

No caso, todo efeito de doses é praticamente linear (91,4%).

### Técnicas práticas para construção dos contrastes independentes (ortogonais).

Se há t tratamentos, há (t- 1) contrastes independentes e soma das suas somas de quadrados é igual a soma de quadrados de tratamentos.

1) Esquema de bipartição não superposta.

Se há t tratamentos, há (t- 1) bipartição não superpostas ou não entrelaçadas.

Inicia-se com um contraste, dividindo os t tratamentos em dois grupos, na seqüência cada novo contraste é obtido por bipartição do subgrupo até que formem subgrupos unitários. Esse esquema pode ser visto nos casos 1 e 2.

Nesse caso, pode-se também usar o esquema de partição entre grupos e dentro de grupos, conforme será ilustrado na aula.

2) Esquema de contrastes e suas interações, criam-se contrastes ortogonais para efeitos principais e para interações, pelo produto dois a dois, usado no caso 3.

3) Esquema de polinômios ortogonais, usado no caso 4. Na literatura esse assunto pode ser visto (p. ex.: polinômios de Fisher, para o caso de eqüidistância das doses, polinômios de Robson, para o caso geral).

4) Esquemas de matrizes ortogonais, usadas em matemática (p. ex: Helmert, Hadamard, Profile, Means e outras). Em modelos lineares, essas matrizes são estudadas com detalhes.

## **Balanceamento/ desbalanceamento**

Quando o número de repetições dos tratamentos é o mesmo, é dito que os dados são balanceados e podem ser usados os esquemas citados até aqui.

Para o caso de desbalanceamento, o procedimento correto exige técnicas de modelos lineares, construindo contrastes cuja covariância seja nula. Na prática, é usual utilizar análises aproximadas, usando um número de  $rh =$  repetições harmônico (média harmônica). Se há  $t$  tratamentos, a fórmula é

$$(1/rh) = (1/t) (1/r_1 + 1/r_2 + \dots + 1/r_t).$$

## **Contrastes não independentes**

Eventualmente podem ser usados contrastes não independentes, mas o fato da covariância entre eles não ser nula, leva diferentes intensidades de dependência, e torna-se difícil calcular o nível de significância global ou conjunta .

## **Modelos lineares e usos em pacotes computacionais**

Para calcular contrastes , usando modelos lineares, uma forma interessante é a criação de variáveis auxiliares. Cria-se uma variável auxiliar que recebe um valor diferente, em cada subgrupo da bipartição. Perecin et al. (2000) mostram vários exemplos dessa técnica.

## **Referências**

O'NEILL, R, & WETHERILL, G.B. The present state of multiple comparison methods. J.Royal Stat. Soc., B. 33: 218-250, 1971.

PERECIN, D., MALHEIROS, E.B., PEREIRA, G.T. Variáveis auxiliares para expressar desdobramento de graus de liberdade e contrastes com o programa SAS. In: RBRAS, 45, São Carlos/SP. 2000. Anais ... p.137-140.

## 2) ANEXO 2: ANÁLISE DE INFESTAÇÕES

No geral, se trabalha com contagens. A disposição na área pode ser de três tipos: ao acaso ou aleatória, com agregação ou em reboleiras , uniforme ou regular.

Há uma relação esperada entre a variância ( $V$ ) e a média ( $M$ ) das contagens: ao acaso ou aleatória,  $V=M$ , com agregação ou em reboleiras,  $V>M$  (sobredispersão), uniforme ou regular,  $V<M$  (subdispersão).

Outra forma usual para avaliar essa dispersão é pelos semivariogramas e mapas, obtidos com auxílio da geoestatística (Vieira et al., 1983).

### DINÂMICA DA INFESTAÇÃO

Embora possam existir outros casos, no geral a infestação inicia-se ao acaso ou aleatória, em pontos isolados da área, multiplica-se de forma agregada ou em reboleiras, com o tempo toma-se toda área, tornando-se uniforme. Nesse processo, a variância inicia-se igual a média, aumenta até um máximo, e diminui até a uniformização.

Com semeadura, a infestação pode ficar uniforme!!! *Portanto, semear na área experimental, é uma boa estratégia para melhorar a precisão experimental.*

### AMOSTRAGEM DA INFESTAÇÃO

A amostragem é fortemente dependente da dinâmica e depende do seu estágio, sendo mais complexa no caso agregada.

Se as unidades de amostragem forem pequenas e bem distribuídas na área, a distribuição amostral se comporta como aleatória (aleatorização por construção). Se a sobredispersão for de até 20% ( $(V/M)<1,2$ ), pode-se trabalhar, para fins práticos, como se fosse aleatória (Perecin & Barbosa, 1994).

Os pesquisadores procuram encontrar o tamanho da amostra (número de repetições ou tamanho da amostra) e também em métodos expeditos e precisos para estimação da resposta dos tratamentos, tanto em áreas experimentais como também em áreas comerciais.

Uma estratégia interessante : Encontrar área de amostragem em que  $((V/M)<1,2)$  e o CV esteja entre 20-30%. O CV para amostra composta por  $m$  dessas áreas originais, pode ser estimado por  $CV= 25/(m)^{1/2}$ . Para um  $CV =10\%$ ,  $m= 25^2/(10^2) =6$  pontos.

Ou seja, a precisão experimental pode ser pré-escolhida !!!

Isso é válido para parcelas ou para talhões uniformes.

## PARCELAS PAREADAS

Uma estratégia interessante é construir delineamentos com parcelas pareadas, uma tratada (T) e outra pareada (P) para controle.

Trabalhar com as diferenças (T-P) e testar se as médias das diferenças é zero. Para isso: Construir a estatística  $TC = \text{dif}(T-P)/(\text{QMRes}/\text{rep})^{1/2}$ , onde rep= (repetições), QMres=Quadrado médio do resíduo.

Usando a distribuição t, o valor mínimo significativo para diferir de zero (em valor absoluto) deve ser menor que o valor de referência (~2, para nível de significância de 5%).

Detalhes dessa técnica podem ser vistos em Perecin et al. (2011).

## TRANSFORMAÇÕES PARA ANÁLISE DOS DADOS

Para análise de variância há necessidade de vários pré-requisitos, sendo importante a homogeneidade da variância. As variâncias das contagens dependem da distribuição : Se aleatória,  $V=M$ , a variância depende da média do tratamento e não haverá homogeneidade se os tratamentos tiverem médias diferentes, usa-se raiz quadrada para homogeneizar as variâncias; Se agregada ou sobredispersa,  $V>>M$ , usa-se logarítmica (contagem +1); Se regular ou subdispersa, não há necessidade de transformações para esse propósito.

Algumas variáveis respostas (RESP), mesmo contagens, mostram desvio padrão proporcional à média. Pode-se verificar essa relação pelo diagrama de dispersão, determinar a reta  $y = a + b x$ , plotando-se:  $x = \log(\text{média})$  versus  $y = \log(\text{desvio padrão})$ . Box et al. (1978) mostram as transformações que estabilizam a variância, para esses casos:

$b=2,0$ , recíproca :  $\text{RESPT}(1) = \text{RESP}^{-1}$ ;

$b=1,5$ , recíproca da raiz quadrada :  $\text{RESPT}(2) = \text{RESP}^{-1/2}$ ;

$b=1,0$ , logarítmica :  $\text{RESPT}(3) = \text{LOG}(\text{RESP})$ ;

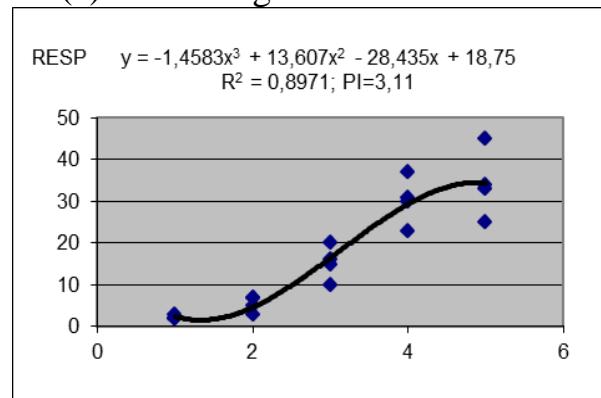
$b=0,5$ , raiz quadrada :  $\text{RESPT}(4) = \text{RESP}^{1/2}$ ;

$b=0$ , não use transformação .

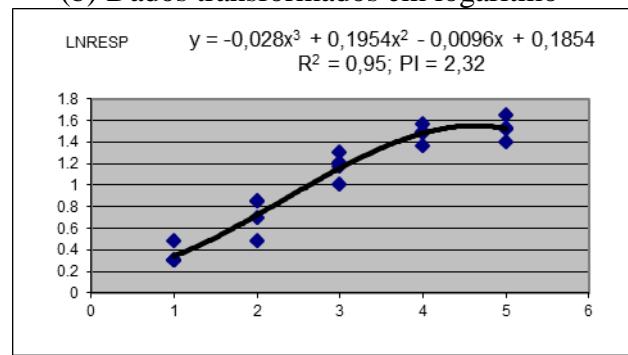
Exemplo: Seja um caso hipotético, em que se avalia o crescimento de uma espécie de planta daninha ao longo de 5 tempos, com 4 repetições por tempo. Na Figura (a), dados originais, verifica-se que não há homogeneidade de variância para a resposta (RESP), eixo das ordenadas, dentro de cada um dos tempos, eixo da abscissa. A relação entre  $x = \log(\text{média})$  versus  $y = \log(\text{desvio padrão})$ , não apresentadas aqui, mostram ( $b \sim 1$ ) e sugerem, pelo critério do item anterior, a transformação logarítmica. Isso foi feito e é mostrado na Figura (b). Nota-se na Figura (b), a homogeneidade de variância para o logaritmo da resposta

(LNRESP), eixo das ordenadas, dentro de cada um dos tempos, eixo da abscissa. Nota-se também na Figura (b) que o  $R^2$  melhora e que o ponto de inflexão (PI) diminui.

(a) Dados originais



(b) Dados transformados em logaritmo



## Referências

BOX, G. E. P., HUNTER, W. G., and HUNTER, J. S. Statistics for experimenters: An introduction to design, data analysis, and model building. John Wiley , 1978.

PERECIN, D. ; BARBOSA, J.C. Afinidade entre distribuições de contagio e Poisson para fins práticos de amostragem. Rev. Mat. Estat., São Paulo, v12, p.107-112, 1994.

PERECIN, D.;AZANIA, C.A.M.; FERRAUDO, G.M.; SCHIAVETTO, A.R. Delineamento com parcelas pareadas. Usos e análises estatísticas. In: Reunião Anual da Região Brasileira da Sociedade Internacional de Biometria, 56, e Simpósio de Estatística Aplicada a Agronomia, 14., 2011, Maringá, PR. ANAIS... Un. Estadual de Maringá, PR, 2011.

VIEIRA, S.R.; HATFIELD, J.L.; NIELSEN, D.R.; BIGGAR, J.W. geoestatistical theory and application to variability of some agronomical properties. Hilgardia, v. 51, p.1-75, 1983.

5,99  
5,59  
5,32 Límites unilaterais de F ao nível de 5% de probabilidade.

	7	8	9	10	11	12	13	14	15	16	20	24	30	40	60	120	∞	
5,12	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	20	24	
4,96	199,5	215,7	224,6	230,2	234,0	236,8	238,9	240,5	241,9	243,0	243,9	244,4	245,0	246,0	248,0	249,1	251,1	252,2
10	4,84	19,00	19,16	19,25	19,30	19,33	19,35	19,37	19,38	19,40	19,42	19,43	19,45	19,46	19,47	19,48	19,49	19,50
11	4,75	9,55	9,28	9,12	9,01	8,94	8,89	8,85	8,81	8,79	8,74	8,71	8,70	8,69	8,66	8,64	8,62	8,59
12	4,67	6,59	6,39	6,26	6,16	6,09	6,04	6,00	5,96	5,93	5,91	5,89	5,87	5,86	5,84	5,80	5,77	5,75
13	4,60	6,94	6,59	6,39	6,16	6,09	6,04	6,00	5,96	5,93	5,91	5,89	5,87	5,86	5,84	5,80	5,77	5,75
14	4,54	5,79	5,41	5,19	5,05	4,95	4,88	4,82	4,77	4,74	4,70	4,68	4,66	4,64	4,62	4,60	4,56	4,53
15	4,49	4,76	4,53	4,39	4,28	4,21	4,15	4,10	4,06	4,03	4,00	3,98	3,96	3,94	3,92	3,87	3,84	3,81
16	4,45	4,74	4,35	4,12	3,97	3,87	3,79	3,73	3,68	3,64	3,60	3,57	3,55	3,52	3,51	3,49	3,44	3,41
17	4,46	4,07	3,84	3,69	3,58	3,50	3,44	3,39	3,35	3,31	3,28	3,25	3,23	3,22	3,20	3,15	3,12	3,08
18	4,26	3,86	3,63	3,48	3,37	3,29	3,23	3,18	3,14	3,10	3,07	3,04	3,02	3,01	2,98	2,94	2,90	2,86
19	4,38	3,71	3,48	3,33	3,22	3,14	3,07	3,02	2,98	2,94	2,91	2,88	2,86	2,82	2,77	2,74	2,70	2,66
20	4,35	3,71	3,59	3,36	3,20	3,09	3,01	2,95	2,90	2,85	2,82	2,79	2,76	2,74	2,72	2,70	2,65	2,61
21	4,32	3,98	3,59	3,36	3,20	3,09	3,01	2,95	2,90	2,85	2,82	2,79	2,76	2,74	2,72	2,70	2,65	2,61
22	4,30	3,89	3,49	3,26	3,11	3,00	2,91	2,85	2,80	2,75	2,72	2,69	2,66	2,64	2,62	2,60	2,54	2,51
23	4,28	3,81	3,41	3,18	3,03	2,92	2,83	2,77	2,71	2,67	2,63	2,60	2,57	2,55	2,53	2,51	2,46	2,42
24	4,26	3,74	3,34	3,11	2,96	2,85	2,76	2,70	2,65	2,60	2,56	2,53	2,50	2,48	2,46	2,44	2,39	2,35
25	4,24	3,68	3,29	3,06	2,90	2,79	2,71	2,64	2,59	2,54	2,51	2,48	2,45	2,43	2,40	2,39	2,33	2,29
26	4,23	3,63	3,24	3,01	2,85	2,74	2,66	2,59	2,54	2,49	2,45	2,42	2,39	2,35	2,33	2,28	2,24	2,19
27	4,21	3,59	3,20	2,96	2,81	2,70	2,61	2,55	2,49	2,45	2,41	2,38	2,35	2,33	2,31	2,29	2,23	2,19
28	4,20	3,55	3,16	2,93	2,77	2,66	2,58	2,51	2,46	2,41	2,37	2,34	2,31	2,29	2,27	2,25	2,19	2,15
29	4,18	3,52	3,13	2,90	2,74	2,63	2,54	2,48	2,42	2,38	2,34	2,31	2,28	2,26	2,23	2,21	2,16	2,11
30	4,17	3,49	3,10	2,87	2,71	2,60	2,51	2,45	2,39	2,35	2,31	2,28	2,25	2,23	2,20	2,18	2,12	2,08
31	4,08	3,07	2,84	2,68	2,57	2,49	2,42	2,37	2,32	2,28	2,25	2,22	2,20	2,18	2,15	2,10	2,05	2,01
32	4,00	3,05	2,82	2,66	2,55	2,46	2,40	2,34	2,30	2,26	2,23	2,20	2,18	2,15	2,13	2,10	2,07	2,03
33	3,92	3,03	2,80	2,64	2,53	2,44	2,37	2,32	2,27	2,24	2,20	2,17	2,14	2,13	2,10	2,05	2,01	1,96
34	3,40	3,01	2,78	2,62	2,51	2,42	2,36	2,30	2,25	2,22	2,18	2,15	2,13	2,11	2,09	2,03	1,98	1,94
35	3,84	3,39	2,99	2,76	2,60	2,49	2,40	2,34	2,28	2,24	2,20	2,16	2,13	2,11	2,09	2,06	2,01	1,96
36	3,37	2,98	2,74	2,59	2,47	2,39	2,32	2,27	2,22	2,18	2,15	2,12	2,10	2,07	2,05	1,99	1,95	1,90
37	3,35	2,96	2,73	2,57	2,46	2,37	2,31	2,25	2,20	2,16	2,13	2,10	2,08	2,06	2,03	1,97	1,93	1,88
38	3,34	2,95	2,71	2,56	2,45	2,36	2,29	2,24	2,19	2,15	2,12	2,09	2,06	2,04	2,02	1,96	1,91	1,87
39	3,33	2,93	2,70	2,55	2,43	2,35	2,28	2,22	2,18	2,14	2,10	2,07	2,05	2,03	2,00	1,94	1,90	1,85
40	1,161,4	3,32	2,92	2,69	2,53	2,42	2,33	2,27	2,21	2,16	2,12	2,09	2,06	2,04	2,01	1,99	1,93	1,89
41	1,18,51	3,23	2,84	2,61	2,45	2,34	2,25	2,18	2,12	2,08	2,04	2,00	1,97	1,95	1,92	1,90	1,84	1,81
42	1,10,13	3,15	2,76	2,53	2,37	2,25	2,17	2,10	2,04	1,99	1,95	1,92	1,89	1,86	1,84	1,81	1,79	1,76
43	1,71	3,07	2,68	2,45	2,29	2,17	2,09	2,02	1,96	1,91	1,86	1,83	1,80	1,77	1,75	1,73	1,70	1,66
44	6,6	3,00	2,60	2,37	2,21	2,10	2,01	1,94	1,88	1,83	1,79	1,75	1,72	1,69	1,67	1,64	1,57	1,52

TABELA 1 - Límites unilaterais de F ao nível de 5% de probabilidade.

T1

T2

T3

T4

T5

T6

T7

T8

T9

T10

T11

T12

T13

T14

T15

T16

T17

T18

TABELA 2 - Limites unilaterais de F ao nível de 1% de probabilidade.

$n_1$	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	20	24	30	40	60	120	$\infty$	
$n_2$																								
1	4052	5000	5403	5625	5764	5859	5928	6022	6056	6082	6106	6125	6142	6157	6169	6209	6235	6261	6287	6313	6339	6366		
2	98,50	99,00	99,17	99,25	99,30	99,33	99,36	99,37	99,39	99,40	99,41	99,42	99,43	99,44	99,45	99,46	99,47	99,48	99,49	99,49	99,50			
3	34,12	30,82	29,46	28,71	28,24	27,91	27,67	27,49	27,35	27,23	27,13	27,05	26,98	26,92	26,87	26,83	26,69	26,60	26,50	26,41	26,32	26,22	26,13	
4	21,20	18,00	16,69	15,98	15,52	15,21	14,98	14,80	14,66	14,55	14,45	14,37	14,30	14,24	14,20	14,15	14,02	13,93	13,84	13,75	13,65	13,56	13,46	
5	16,26	13,27	12,06	11,39	10,97	10,67	10,46	10,29	10,16	10,05	9,96	9,89	9,83	9,77	9,72	9,68	9,55	9,47	9,38	9,29	9,20	9,11	9,02	
6	13,75	10,92	9,78	9,15	8,75	8,47	8,26	8,10	7,98	7,87	7,79	7,72	7,66	7,60	7,56	7,52	7,40	7,31	7,23	7,14	7,06	6,97	6,88	
7	12,25	9,55	8,45	7,85	7,46	7,19	6,99	6,84	6,72	6,62	6,54	6,47	6,41	6,35	6,31	6,27	6,16	6,07	5,99	5,91	5,82	5,74	5,65	
8	11,26	8,65	7,59	7,01	6,63	6,37	6,18	6,03	5,91	5,81	5,74	5,67	5,61	5,56	5,52	5,48	5,36	5,28	5,20	5,12	5,03	4,95	4,86	
9	10,56	8,02	6,99	6,42	6,06	5,80	5,61	5,47	5,35	5,26	5,18	5,11	5,05	5,00	4,96	4,92	4,81	4,73	4,65	4,57	4,48	4,40	4,31	
10	10,04	7,56	6,55	5,99	5,64	5,39	5,20	5,06	4,94	4,85	4,78	4,71	4,65	4,60	4,56	4,52	4,41	4,33	4,25	4,17	4,08	4,00	3,91	
11	9,65	7,21	6,22	5,67	5,32	5,07	4,89	4,74	4,63	4,54	4,46	4,40	4,34	4,29	4,25	4,21	4,10	4,02	3,94	3,86	3,78	3,69	3,60	
12	9,33	6,93	5,95	5,41	5,06	4,82	4,64	4,50	4,39	4,30	4,22	4,16	4,10	4,05	4,01	3,98	3,86	3,78	3,70	3,62	3,54	3,45	3,36	
13	9,07	6,70	5,74	5,21	4,86	4,62	4,44	4,30	4,19	4,10	4,02	3,96	3,90	3,85	3,82	3,78	3,66	3,59	3,51	3,43	3,34	3,25	3,17	
14	8,86	6,51	5,56	5,04	4,69	4,46	4,28	4,14	4,03	3,94	3,86	3,80	3,75	3,70	3,66	3,62	3,51	3,43	3,35	3,27	3,18	3,09	3,00	
15	8,68	6,36	5,42	4,89	4,56	4,32	4,14	4,00	3,89	3,80	3,73	3,67	3,61	3,56	3,52	3,48	3,37	3,29	3,21	3,13	3,05	2,96	2,87	
16	8,53	6,23	5,29	4,77	4,44	4,20	4,03	3,89	3,78	3,69	3,61	3,55	3,50	3,45	3,41	3,37	3,26	3,18	3,10	3,02	2,93	2,84	2,75	
17	8,40	6,11	5,18	4,67	4,34	4,10	3,93	3,79	3,68	3,59	3,52	3,46	3,40	3,35	3,31	3,27	3,16	3,08	3,00	2,92	2,83	2,75	2,65	
18	8,29	6,01	5,09	4,58	4,25	4,01	3,84	3,71	3,60	3,51	3,44	3,37	3,32	3,27	3,23	3,19	3,08	3,00	2,92	2,84	2,75	2,66	2,57	
19	8,18	5,93	5,01	4,50	4,17	3,94	3,77	3,63	3,52	3,43	3,36	3,30	3,24	3,19	3,15	3,12	3,00	2,92	2,84	2,76	2,67	2,58	2,49	
20	8,10	5,85	4,94	4,43	4,10	3,87	3,70	3,56	3,46	3,37	3,30	3,23	3,18	3,13	3,09	3,05	2,94	2,86	2,78	2,69	2,61	2,52	2,42	
21	8,02	5,78	4,87	4,37	4,04	3,81	3,64	3,51	3,40	3,31	3,24	3,17	3,12	3,07	3,03	2,99	2,88	2,80	2,72	2,64	2,55	2,46	2,36	
22	7,95	5,72	4,82	4,31	3,99	3,76	3,59	3,45	3,35	3,26	3,18	3,12	3,07	3,02	2,98	2,94	2,83	2,75	2,67	2,58	2,50	2,40	2,31	
23	7,88	5,66	4,76	4,26	3,94	3,71	3,54	3,41	3,30	3,21	3,14	3,07	3,02	2,97	2,93	2,89	2,78	2,70	2,62	2,54	2,45	2,35	2,26	
24	7,82	5,61	4,72	4,22	3,90	3,67	3,50	3,36	3,26	3,17	3,09	3,03	2,98	2,93	2,89	2,85	2,74	2,66	2,58	2,49	2,40	2,31	2,21	
25	7,77	5,57	4,68	4,18	3,85	3,63	3,46	3,32	3,22	3,13	3,05	2,99	2,94	2,89	2,85	2,81	2,70	2,62	2,54	2,45	2,36	2,27	2,17	
26	7,72	5,53	4,64	4,14	3,82	3,59	3,42	3,29	3,18	3,09	3,02	2,96	2,91	2,86	2,81	2,77	2,66	2,58	2,50	2,42	2,33	2,23	2,13	
27	7,68	5,49	4,60	4,11	3,78	3,56	3,39	3,26	3,15	3,06	2,98	2,93	2,88	2,83	2,78	2,74	2,63	2,55	2,47	2,38	2,29	2,20	2,10	
28	7,64	5,45	4,57	4,07	3,75	3,53	3,36	3,23	3,12	3,03	2,95	2,90	2,85	2,80	2,75	2,71	2,60	2,52	2,44	2,35	2,26	2,17	2,06	
29	7,60	5,42	4,54	4,04	3,73	3,50	3,33	3,20	3,09	3,00	2,92	2,87	2,82	2,77	2,73	2,68	2,57	2,49	2,41	2,33	2,23	2,14	2,03	
30	7,56	5,39	4,51	4,02	3,70	3,47	3,30	3,17	3,07	2,98	2,90	2,84	2,79	2,74	2,70	2,66	2,55	2,47	2,39	2,30	2,21	2,11	2,01	
40	7,31	5,18	4,31	3,83	3,51	3,29	3,12	2,99	2,89	2,80	2,73	2,66	2,61	2,56	2,52	2,49	2,37	2,29	2,20	2,11	2,02	1,92	1,80	
60	7,08	4,98	4,13	3,65	3,34	3,12	2,95	2,82	2,72	2,63	2,56	2,50	2,45	2,40	2,35	2,32	2,20	2,12	2,03	1,94	1,84	1,73	1,60	
120	6,85	4,79	3,95	3,48	3,17	2,96	2,79	2,66	2,56	2,47	2,40	2,34	2,29	2,24	2,19	2,16	2,03	1,95	1,86	1,76	1,66	1,53	1,38	
$\infty$	6,63	4,61	3,78	3,32	3,02	2,80	2,64	2,51	2,41	2,32	2,24	2,18	2,12	2,07	2,04	1,99	1,88	1,79	1,70	1,59	1,47	1,32	1,00	

**TABELA 3 – Valores de t em níveis de 10% a 0,1% de probabilidade.**

G.L. Resíduo	10%	5%	2%	1%	0,1%
1	6,31	12,71	31,82	63,66	636,62
2	2,92	4,30	6,97	9,92	31,60
3	2,35	3,18	4,54	5,84	12,94
4	2,13	2,78	3,75	4,60	8,61
5	2,02	2,57	2,37	4,03	6,86
6	1,94	2,45	3,14	3,71	5,96
7	1,90	2,36	3,10	3,50	5,41
8	1,86	2,31	2,90	3,36	5,04
9	1,83	2,26	2,82	3,25	4,78
10	1,81	2,23	2,76	3,17	4,59
11	1,80	2,20	2,72	3,11	4,44
12	1,78	2,18	2,68	3,06	4,32
13	1,77	2,16	2,65	3,01	4,22
14	1,76	2,14	2,62	2,98	4,14
15	1,75	2,13	2,60	2,95	4,07
16	1,75	2,12	2,58	2,92	4,02
17	1,74	2,11	2,57	2,90	3,97
18	1,73	2,10	2,55	2,88	3,92
19	1,73	2,09	2,54	2,86	3,88
20	1,73	2,09	2,53	2,84	3,85
21	1,72	2,08	2,52	2,83	3,82
22	1,72	2,07	2,51	2,82	3,79
23	1,71	2,07	2,50	2,81	3,77
24	1,71	2,06	2,49	2,80	3,75
25	1,71	2,06	2,49	2,79	3,73
26	1,71	2,06	2,48	2,78	3,71
27	1,70	2,05	2,47	2,77	3,69
28	1,70	2,05	2,47	2,76	3,67
29	1,70	2,04	2,46	2,76	3,66
30	1,70	2,04	2,46	2,75	3,65
40	1,68	2,02	2,42	2,70	3,55
60	1,67	2,00	2,39	2,66	3,46
120	1,65	1,98	2,36	2,62	3,37
$\infty$	1,65	1,96	2,33	2,58	3,29

**TABELA 4 – Valores da amplitude total estudentizada (q), para uso no teste de Tukey, ao nível de 5% de probabilidade.**  
 n = número de tratamentos.  
 n' = número de graus de liberdade do resíduo.

n n'	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
1	17,97	26,98	32,82	37,08	40,41	43,12	45,40	47,36	49,07	50,59	51,96	53,20	54,33	55,36	56,32	57,22	58,04	58,83	59,56
2	6,09	8,33	9,80	10,88	11,74	12,44	13,03	13,54	13,99	14,39	14,75	15,08	15,33	15,65	15,91	16,14	16,37	16,57	16,77
3	4,50	5,91	6,83	7,50	8,04	8,48	8,85	9,18	9,46	9,72	9,95	10,15	10,35	10,53	10,69	10,84	10,98	11,11	11,24
4	3,93	5,04	5,76	6,29	6,71	7,05	7,35	7,60	7,83	8,03	8,21	8,37	8,53	8,66	8,79	8,91	9,03	9,13	9,23
5	3,64	4,60	5,22	5,67	6,03	6,33	6,58	6,80	7,00	7,17	7,32	7,47	7,60	7,72	7,83	7,93	8,03	8,12	8,21
6	3,46	4,34	4,90	5,31	5,63	5,90	6,12	6,32	6,49	6,65	6,79	6,92	7,03	7,14	7,24	7,34	7,43	7,51	7,59
7	3,34	4,17	4,68	5,06	5,36	5,61	5,82	6,00	6,16	6,30	6,43	6,55	6,66	6,76	6,85	6,94	7,02	7,10	7,17
8	3,26	4,04	4,53	4,89	5,17	5,40	5,60	5,77	5,92	6,05	6,18	6,29	6,39	6,48	6,57	6,65	6,73	6,80	6,87
9	3,20	3,95	4,42	4,76	5,02	5,24	5,43	5,60	5,74	5,87	5,98	6,09	6,19	6,28	6,36	6,44	6,51	6,58	6,64
10	3,15	3,88	4,33	4,65	4,91	5,12	5,31	5,46	5,60	5,72	5,83	5,94	6,03	6,11	6,19	6,27	6,34	6,41	6,47
11	3,11	3,82	4,26	4,57	4,82	5,03	5,20	5,35	5,49	5,61	5,71	5,81	5,90	5,98	6,06	6,13	6,20	6,27	6,33
12	3,08	3,77	4,20	4,51	4,75	4,95	5,12	5,27	5,40	5,51	5,62	5,71	5,80	5,88	5,95	6,02	6,09	6,15	6,21
13	3,06	3,74	4,15	4,45	4,69	4,89	5,05	5,19	5,32	5,43	5,53	5,63	5,71	5,79	5,86	5,93	6,00	6,06	6,11
14	3,03	3,70	4,11	4,41	4,64	4,83	4,99	5,13	5,25	5,36	5,46	5,55	5,64	5,71	5,79	5,85	5,92	5,97	6,03
15	3,01	3,67	4,08	4,37	4,60	4,78	4,94	5,08	5,20	5,31	5,40	5,49	5,57	5,65	5,72	5,79	5,85	5,90	5,96
16	3,00	3,65	4,05	4,33	4,56	4,74	4,90	5,03	5,15	5,26	5,35	5,44	5,52	5,59	5,66	5,73	5,79	5,84	5,90
17	2,98	3,63	4,02	4,30	4,52	4,71	4,86	4,99	5,11	5,21	5,31	5,39	5,47	5,54	5,61	5,68	5,73	5,79	5,84
18	2,97	3,61	4,00	4,28	4,50	4,67	4,82	4,96	5,07	5,17	5,27	5,35	5,43	5,50	5,57	5,63	5,69	5,74	5,79
19	2,96	3,59	3,98	4,25	4,47	4,65	4,79	4,92	5,04	5,14	5,23	5,32	5,39	5,46	5,53	5,59	5,65	5,70	5,75
20	2,95	3,58	3,96	4,23	4,45	4,62	4,77	4,90	5,01	5,11	5,20	5,28	5,36	5,43	5,49	5,55	5,61	5,66	5,71
24	2,92	3,53	3,90	4,17	4,37	4,54	4,68	4,81	4,92	5,01	5,10	5,18	5,25	5,32	5,38	5,44	5,55	5,59	5,63
30	2,89	3,49	3,85	4,10	4,30	4,46	4,60	4,72	4,82	4,92	5,00	5,08	5,15	5,21	5,27	5,33	5,38	5,43	5,48
40	2,86	3,44	3,79	4,04	4,23	4,39	4,52	4,64	4,74	4,82	4,90	4,98	5,04	5,11	5,16	5,22	5,27	5,31	5,36
60	2,83	3,40	3,74	3,98	4,16	4,31	4,44	4,55	4,65	4,73	4,81	4,88	4,94	5,00	5,06	5,11	5,15	5,20	5,24
120	2,80	3,36	3,69	3,92	4,10	4,24	4,36	4,47	4,56	4,64	4,71	4,78	4,84	4,90	4,95	5,00	5,04	5,09	5,13
∞	2,77	3,31	3,63	3,86	4,03	4,17	4,29	4,39	4,47	4,55	4,62	4,69	4,74	4,80	4,85	4,89	4,93	4,97	5,01

TABELA 5 – Valores da amplitude total estudentizada (z), para uso no teste de Duncan, ao nível de 5% de probabilidade.

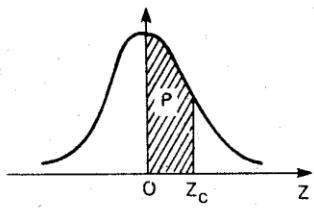
 $n$  = número de médias abrangidas pelo contraste. $n'$  = número de graus de liberdade do resíduo.

$n'$	1	2	3	4	5	6	7	8	9	10	12	14	16	18	20	50	100
1	18,00	18,00	18,00	18,00	18,00	18,00	18,00	18,00	18,00	18,00	18,00	18,00	18,00	18,00	18,00	18,00	18,00
2	6,09	6,09	6,09	6,09	6,09	6,09	6,09	6,09	6,09	6,09	6,09	6,09	6,09	6,09	6,09	6,09	6,09
3	4,50	4,50	4,50	4,50	4,50	4,50	4,50	4,50	4,50	4,50	4,50	4,50	4,50	4,50	4,50	4,50	4,50
4	3,93	4,01	4,02	4,02	4,02	4,02	4,02	4,02	4,02	4,02	4,02	4,02	4,02	4,02	4,02	4,02	4,02
5	3,64	3,74	3,79	3,83	3,83	3,83	3,83	3,83	3,83	3,83	3,83	3,83	3,83	3,83	3,83	3,83	3,83
6	3,46	3,58	3,64	3,68	3,68	3,68	3,68	3,68	3,68	3,68	3,68	3,68	3,68	3,68	3,68	3,68	3,68
7	3,35	3,47	3,54	3,58	3,60	3,61	3,61	3,61	3,61	3,61	3,61	3,61	3,61	3,61	3,61	3,61	3,61
8	3,26	3,39	3,47	3,52	3,55	3,56	3,56	3,56	3,56	3,56	3,56	3,56	3,56	3,56	3,56	3,56	3,56
9	3,20	3,34	3,41	3,47	3,50	3,52	3,52	3,52	3,52	3,52	3,52	3,52	3,52	3,52	3,52	3,52	3,52
10	3,15	3,30	3,37	3,43	3,46	3,47	3,47	3,47	3,47	3,47	3,47	3,47	3,47	3,47	3,47	3,48	3,48
11	3,11	3,27	3,35	3,39	3,43	3,44	3,44	3,45	3,45	3,46	3,46	3,46	3,46	3,46	3,46	3,48	3,48
12	3,08	3,23	3,33	3,36	3,40	3,42	3,42	3,44	3,44	3,46	3,46	3,46	3,46	3,46	3,46	3,48	3,48
13	3,06	3,21	3,30	3,35	3,38	3,41	3,42	3,44	3,45	3,45	3,46	3,46	3,46	3,46	3,47	3,47	3,47
14	3,03	3,18	3,27	3,33	3,37	3,39	3,41	3,42	3,44	3,45	3,46	3,46	3,46	3,46	3,47	3,47	3,47
15	3,01	3,16	3,25	3,31	3,36	3,38	3,40	3,42	3,43	3,44	3,45	3,45	3,46	3,46	3,47	3,47	3,47
16	3,00	3,15	3,23	3,30	3,34	3,37	3,39	3,41	3,43	3,44	3,45	3,45	3,46	3,46	3,47	3,47	3,47
17	2,98	3,13	3,22	3,28	3,33	3,36	3,38	3,40	3,42	3,44	3,45	3,46	3,46	3,47	3,47	3,47	3,47
18	2,97	3,12	3,21	3,27	3,32	3,35	3,37	3,39	3,41	3,43	3,45	3,46	3,46	3,47	3,47	3,47	3,47
19	2,96	3,11	3,19	3,26	3,31	3,35	3,37	3,39	3,41	3,43	3,44	3,46	3,46	3,47	3,47	3,47	3,47
20	2,95	3,10	3,18	3,25	3,30	3,34	3,36	3,38	3,40	3,43	3,44	3,46	3,46	3,47	3,47	3,47	3,47
22	2,93	3,08	3,17	3,24	3,29	3,32	3,35	3,37	3,39	3,42	3,44	3,45	3,46	3,46	3,47	3,47	3,47
24	2,92	3,07	3,15	3,22	3,28	3,31	3,34	3,37	3,38	3,41	3,44	3,45	3,46	3,46	3,47	3,47	3,47
26	2,91	3,06	3,14	3,21	3,27	3,30	3,34	3,36	3,38	3,41	3,43	3,45	3,46	3,46	3,47	3,47	3,47
28	2,90	3,04	3,13	3,20	3,26	3,30	3,33	3,35	3,37	3,40	3,43	3,45	3,46	3,46	3,47	3,47	3,47
30	2,89	3,04	3,12	3,20	3,25	3,29	3,32	3,35	3,37	3,40	3,43	3,44	3,46	3,46	3,47	3,47	3,47
40	2,86	3,01	3,10	3,17	3,22	3,27	3,30	3,33	3,35	3,39	3,42	3,44	3,46	3,46	3,47	3,47	3,47
60	2,83	2,98	3,08	3,14	3,20	3,24	3,28	3,31	3,33	3,37	3,40	3,43	3,45	3,45	3,48	3,48	3,48
100	2,80	2,95	3,05	3,12	3,18	3,22	3,26	3,29	3,32	3,36	3,40	3,42	3,45	3,45	3,53	3,53	3,53
$\infty$	2,77	2,92	3,02	3,09	3,15	3,19	3,23	3,26	3,29	3,34	3,38	3,41	3,44	3,44	3,61	3,61	3,67

TÁBUA V

Distribuição de Student:  $St(n)$   
Valores críticos de  $t$  tais que  $P(-t_c < t < t_c) = 1 - p$

		Graus de liberdade													
		Graus de liberdade													
		Graus de liberdade													
p = 90%	80%	70%	60%	50%	40%	30%	20%	10%	5%	4%	2%	1%	0,2%	0,1%	
1	0,158	0,325	0,510	0,727	1,000	1,376	1,963	3,078	6,314	12,706	15,894	31,821	63,657	318,309	636,619
2	0,142	0,289	0,445	0,617	0,816	1,061	1,386	2,920	4,303	4,849	6,965	9,925	22,327	31,598	1
3	0,137	0,277	0,424	0,584	0,765	0,978	1,250	2,353	3,182	3,482	4,541	5,841	10,214	12,924	2
4	0,134	0,271	0,414	0,569	0,741	0,941	1,190	1,533	2,132	2,776	2,998	3,747	4,604	7,173	8,610
5	0,132	0,267	0,408	0,559	0,727	0,920	1,156	1,476	2,015	2,571	2,756	3,365	4,032	5,893	6,869
6	0,131	0,265	0,404	0,553	0,718	0,906	1,134	1,440	1,943	2,447	2,612	3,143	3,707	5,208	5,959
7	0,130	0,263	0,402	0,549	0,711	0,896	1,119	1,415	1,895	2,365	2,517	3,499	4,785	5,408	
8	0,130	0,262	0,399	0,546	0,706	0,889	1,108	1,397	1,860	2,306	2,449	2,896	3,355	4,501	5,041
9	0,129	0,261	0,398	0,543	0,703	0,883	1,100	1,383	1,833	2,262	2,398	2,821	3,250	4,297	4,781
10	0,129	0,260	0,397	0,542	0,700	0,879	1,093	1,372	1,812	2,228	2,359	2,764	3,169	4,144	4,587
11	0,129	0,260	0,396	0,540	0,697	0,876	1,088	1,363	1,796	2,201	2,328	2,718	3,106	3,025	4,437
12	0,128	0,259	0,395	0,539	0,695	0,873	1,083	1,356	1,782	2,179	2,303	2,681	3,055	3,930	4,318
13	0,128	0,259	0,394	0,538	0,694	0,870	1,079	1,350	1,771	2,160	2,282	2,650	3,012	3,852	4,221
14	0,128	0,258	0,393	0,537	0,692	0,868	1,076	1,345	1,761	2,145	2,264	2,624	2,977	3,787	4,140
15	0,128	0,258	0,393	0,536	0,691	0,866	1,074	1,341	1,753	2,131	2,248	2,602	2,947	3,733	4,073
16	0,128	0,258	0,392	0,535	0,690	0,865	1,071	1,337	1,746	2,120	2,235	2,583	2,921	3,686	4,016
17	0,128	0,257	0,392	0,534	0,689	0,863	1,069	1,333	1,740	2,110	2,224	2,567	2,898	3,646	4,065
18	0,127	0,257	0,392	0,534	0,688	0,862	1,067	1,330	1,734	2,101	2,214	2,552	2,878	3,610	3,922
19	0,127	0,257	0,391	0,533	0,688	0,861	1,066	1,328	1,729	2,093	2,205	2,539	2,861	3,579	3,883
20	0,127	0,257	0,391	0,533	0,687	0,860	1,064	1,325	1,725	2,086	2,197	2,528	2,845	3,552	3,850
21	0,127	0,257	0,391	0,532	0,686	0,859	1,063	1,323	1,721	2,080	2,189	2,518	2,831	3,527	3,819
22	0,127	0,256	0,390	0,532	0,686	0,858	1,061	1,321	1,717	2,074	2,183	2,508	2,819	3,505	3,792
23	0,127	0,256	0,390	0,532	0,685	0,858	1,060	1,319	1,714	2,069	2,177	2,500	2,807	3,485	3,768
24	0,127	0,256	0,390	0,531	0,685	0,857	1,059	1,318	1,711	2,064	2,172	2,492	2,797	3,467	3,745
25	0,127	0,256	0,390	0,531	0,684	0,856	1,058	1,316	1,708	2,060	2,166	2,485	2,787	3,450	3,725
26	0,127	0,256	0,390	0,531	0,684	0,856	1,058	1,315	1,706	2,056	2,162	2,479	2,779	3,435	3,707
27	0,127	0,256	0,389	0,531	0,684	0,855	1,057	1,314	1,703	2,052	2,158	2,473	2,771	3,421	3,690
28	0,127	0,256	0,389	0,530	0,684	0,855	1,056	1,313	1,701	2,048	2,154	2,467	2,763	3,408	3,674
29	0,127	0,256	0,389	0,530	0,683	0,854	1,055	1,311	1,699	2,045	2,150	2,462	2,756	3,396	3,659
30	0,127	0,256	0,389	0,530	0,683	0,854	1,055	1,310	1,697	2,042	2,147	2,457	2,750	3,385	3,646
35	0,126	0,255	0,388	0,529	0,682	0,852	1,052	1,306	1,690	2,030	2,133	2,438	2,724	3,340	3,591
40	0,126	0,255	0,388	0,529	0,681	0,851	1,050	1,303	1,684	2,021	2,123	2,423	2,704	3,307	3,551
50	0,126	0,254	0,387	0,528	0,679	0,849	1,047	1,299	1,676	2,009	2,109	2,403	2,678	3,261	3,496
60	0,126	0,254	0,387	0,527	0,679	0,848	1,045	1,296	1,671	2,000	2,099	2,390	2,660	3,232	3,460
120	0,126	0,254	0,386	0,526	0,677	0,845	1,041	1,289	1,658	1,980	2,076	2,358	2,617	3,160	3,373
$\infty$	0,126	0,253	0,385	0,524	0,674	0,842	1,036	1,282	1,645	1,960	2,054	2,326	2,576	3,090	3,291



TÁBUA III

Distribuição normal reduzida:  $N(0;1)$   
Probabilidades  $p$  tais que  $p = P(0 < Z < Z_c)$

parte inteira e primeira decimal de $Z_c$	SEGUNDA DECIMAL DE $Z_c$										parte inteira e primeira decimal de $Z_c$
	0	1	2	3	4	5	6	7	8	9	
$p = 0$											
0,0	00000	00399	00798	01197	01595	01994	02392	02790	03188	03586	0,0
0,1	03983	04380	04776	05172	05567	05962	06356	06749	07142	07535	0,1
0,2	07926	08317	08706	09095	09483	09871	10257	10642	11026	11409	0,2
0,3	11791	12172	12552	12930	13307	13683	14058	14431	14803	15173	0,3
0,4	15542	15910	16276	16640	17003	17364	17724	18082	18439	18793	0,4
0,5	19146	19497	19847	20194	20540	20884	21226	21566	21904	22240	0,5
0,6	22575	22907	23237	23565	23891	24215	24537	24857	25175	25490	0,6
0,7	25804	26115	26424	26730	27035	27337	27637	27935	28230	28524	0,7
0,8	28814	29103	29389	29673	29955	30234	30511	30785	31057	31327	0,8
0,9	31594	31859	32121	32381	32639	32894	33147	33398	33646	33891	0,9
1,0	34134	34375	34614	34850	35083	35314	35543	35769	35993	36214	1,0
1,1	36433	36650	36864	37076	37286	37493	37698	37900	38100	38298	1,1
1,2	38493	38686	38877	39065	39251	39435	39617	39796	39973	40147	1,2
1,3	40320	40490	40658	40824	40988	41149	41309	41466	41621	41774	1,3
1,4	41924	42073	42220	42364	42507	42647	42786	42922	43056	43189	1,4
1,5	43319	43448	43574	43699	43822	43943	44062	44179	44295	44408	1,5
1,6	44520	44630	44738	44845	44950	45053	45154	45254	45352	45449	1,6
1,7	45543	45637	45728	45818	45907	45994	46080	46164	46246	46327	1,7
1,8	46407	46485	46562	46638	46712	46784	46856	46926	46995	47062	1,8
1,9	47128	47193	47257	47320	47381	47441	47500	47558	47615	47670	1,9
2,0	47725	47778	47831	47882	47932	47982	48030	48077	48124	48169	2,0
2,1	48214	48257	48300	48341	48382	48422	48461	48500	48537	48574	2,1
2,2	48610	48645	48679	48713	48745	48778	48809	48840	48870	48899	2,2
2,3	48928	48956	48983	49010	49036	49061	49086	49111	49134	49158	2,3
2,4	49180	49202	49224	49245	49266	49286	49305	49324	49343	49361	2,4
2,5	49379	49396	49413	49430	49446	49461	49477	49492	49506	49520	2,5
2,6	49534	49547	49560	49573	49585	49598	49609	49621	49632	49643	2,6
2,7	49653	49664	49674	49683	49693	49702	49711	49720	49728	49736	2,7
2,8	49744	49752	49760	49767	49774	49781	49788	49795	49801	49807	2,8
2,9	49813	49819	49825	49831	49836	49841	49846	49851	49856	49861	2,9
3,0	49865	49869	49874	49878	49882	49886	49889	49893	49897	49900	3,0
3,1	49903	49906	49910	49913	49916	49918	49921	49924	49926	49929	3,1
3,2	49931	49934	49936	49938	49940	49942	49944	49946	49948	49950	3,2
3,3	49952	49953	49955	49957	49958	49960	49961	49962	49964	49965	3,3
3,4	49966	49968	49969	49970	49971	49972	49973	49974	49975	49976	3,4
3,5	49977	49978	49979	49980	49981	49981	49982	49983	49983	49983	3,5
3,6	49984	49985	49985	49986	49986	49987	49987	49988	49988	49989	3,6
3,7	49989	49990	49990	49990	49991	49991	49992	49992	49992	49992	3,7
3,8	49993	49993	49993	49994	49994	49994	49994	49995	49995	49995	3,8
3,9	49995	49995	49996	49996	49996	49996	49996	49996	49997	49997	3,9
4,0	49997	49997	49997	49997	49997	49997	49998	49998	49998	49998	4,0
4,5	49999	50000	50000	50000	50000	50000	50000	50000	50000	50000	4,5
parte inteira e primeira decimal de $Z_c$	SEGUNDA E TERCEIRA DECIMAS DE $Z_c$										parte inteira e primeira decimal de $Z_c$
	05	15	25	35	45	55	65	75	85	95	
$p = 0$											
0,0	00199	00598	09997	01396	01795	02193	02591	02989	03387	03784	0,0
0,1	04181	04578	04974	05369	05764	06159	06553	06946	07339	07730	0,1
0,2	08121	08512	08901	09290	09677	10064	10450	10834	11218	11600	0,2
0,3	11982	12362	12741	13119	13495	13871	14244	14617	14988	15358	0,3
0,4	15726	16093	16458	16822	17184	17545	17903	18261	18500	18970	0,4
0,5	19322	19672	20021	20368	20712	21055	21396	21735	22073	22408	0,5
0,6	22741	23072	23401	23729	24054	24377	24697	25016	25333	25647	0,6
0,7	25959	26270	26577	26883	27186	27488	27786	28083	28377	28669	0,7
0,8	28959	29246	29531	29814	30094	30372	30648	30921	31192	31461	0,8
0,9	31727	31990	32252	32511	32767	33021	33273	33522	33769	34013	0,9

**TÁBUA IV**Distribuição de qui-quadrado:  $\chi^2(n)$ 

Valores críticos de qui-quadrado tais que

$$P(\chi^2 > \chi_c^2) = p$$

		Graus de liberdade $n$																
$p = 99\%$	$98\%$	$97.5\%$	$95\%$	$90\%$	$80\%$	$70\%$	$50\%$	$30\%$	$20\%$	$10\%$	$5\%$	$4\%$	$2.5\%$	$2\%$	$1\%$	$0.2\%$	$0.1\%$	
1	0,016	0,063	0,001	0,004	0,016	0,064	0,148	0,455	1,074	1,642	2,706	3,841	4,218	5,024	5,412	6,635	9,550	10,827
2	0,020	0,040	0,051	0,103	0,211	0,446	1,713	1,386	2,408	3,219	4,605	5,991	6,438	7,378	7,824	9,210	12,429	13,815
3	0,115	0,185	0,216	0,352	0,584	1,005	1,424	2,366	3,665	4,642	6,251	7,815	9,311	9,348	9,837	11,345	14,796	16,266
4	0,297	0,429	0,484	0,711	1,064	1,649	2,195	3,357	4,878	5,989	7,779	9,488	10,026	11,143	11,668	13,277	16,924	18,467
5	0,554	0,752	0,831	1,145	1,610	2,343	3,000	4,351	6,064	7,289	9,236	11,070	11,644	12,832	13,388	15,086	18,907	20,515
6	0,872	1,134	1,237	1,635	2,204	3,070	3,828	5,348	7,231	8,558	10,645	12,592	13,198	14,449	15,033	16,812	20,791	22,457
7	1,239	1,564	1,690	2,167	2,833	3,822	4,671	6,346	8,383	9,803	12,017	14,067	14,703	16,013	16,632	18,475	22,601	24,322
8	1,648	2,032	2,180	2,733	3,490	4,594	5,527	7,344	9,524	11,030	13,362	15,507	16,171	17,534	18,168	20,090	24,352	26,125
9	2,088	2,532	2,700	3,325	4,168	5,380	6,393	8,343	10,656	12,242	14,684	16,919	17,608	19,023	19,679	21,666	26,056	27,877
10	2,558	3,059	3,247	3,940	4,865	6,179	7,267	9,342	11,781	13,442	15,987	18,307	19,021	20,483	21,161	23,209	27,722	29,588
11	3,053	3,609	3,816	4,575	5,578	6,989	8,148	10,341	12,899	14,631	17,275	19,675	20,412	21,920	22,618	24,725	29,354	31,264
12	3,571	4,178	4,404	5,226	6,304	7,807	9,034	11,340	14,011	15,812	18,549	21,026	21,785	23,337	24,054	26,217	30,957	32,909
13	4,107	4,765	5,009	5,892	7,042	8,634	9,926	12,340	15,119	16,985	19,812	22,362	23,142	24,736	25,472	27,688	32,535	34,528
14	4,880	5,368	5,629	6,571	7,790	9,467	10,821	13,339	16,222	18,151	21,064	23,685	24,485	26,119	26,873	29,141	34,091	36,123
15	5,229	5,985	6,262	7,261	8,547	10,307	11,721	14,339	17,322	19,311	22,307	24,996	25,816	27,488	28,259	30,578	35,628	37,697
16	5,812	6,614	6,908	7,962	9,312	11,152	12,624	15,338	18,418	20,465	23,542	26,296	27,136	28,845	29,633	32,000	37,146	39,252
17	6,408	7,255	7,564	8,672	10,085	12,002	13,531	16,338	19,511	21,615	24,769	27,587	28,445	30,191	30,995	33,409	38,648	40,790
18	7,015	7,906	8,231	9,390	10,865	12,857	14,440	17,338	20,601	22,760	25,989	28,869	28,745	31,526	32,346	34,805	40,136	42,312
19	7,633	8,567	9,006	10,117	11,651	13,716	15,352	18,338	21,689	23,900	27,204	30,144	31,037	32,852	33,687	36,191	41,610	43,820
20	8,260	9,237	9,591	10,851	12,443	14,578	16,266	19,337	22,775	25,038	28,412	31,410	32,321	34,170	35,020	37,566	43,072	45,315
21	8,897	9,915	10,283	11,591	13,240	15,445	17,182	20,337	23,858	26,171	29,615	32,671	33,597	35,479	36,343	38,932	44,522	46,797
22	9,542	10,600	10,982	12,338	14,041	16,314	18,101	21,337	24,939	27,301	30,813	33,924	34,867	37,781	37,659	40,289	45,962	48,268
23	10,198	11,293	11,688	13,091	14,848	17,187	19,021	22,337	26,018	28,429	32,007	35,172	36,131	38,076	38,968	41,638	47,391	49,728
24	10,856	11,992	12,401	13,848	15,659	18,062	19,943	23,337	27,096	29,553	33,196	36,415	37,389	39,064	40,270	42,980	48,812	51,179
25	11,524	12,697	13,120	14,611	16,473	18,940	20,867	24,337	28,172	30,675	34,382	37,652	38,642	40,646	41,566	44,314	50,223	52,620
26	12,198	13,409	13,844	15,379	17,292	19,820	21,792	25,336	29,246	31,795	35,563	38,885	39,889	41,923	42,856	45,642	51,627	54,052
27	12,879	14,125	14,573	16,151	18,114	20,703	22,719	26,336	30,319	32,912	36,741	40,113	41,132	43,194	44,140	46,963	53,022	55,476
28	13,565	14,847	15,308	16,928	18,939	21,588	23,647	27,336	31,319	34,027	37,916	41,337	42,370	44,461	45,419	48,278	54,411	56,893
29	14,256	15,574	16,047	17,708	19,768	22,475	24,577	28,336	32,461	35,139	39,087	42,557	43,604	45,722	46,693	49,588	55,792	58,302
30	14,953	16,306	16,791	18,493	20,599	23,364	25,508	29,336	33,530	36,250	40,256	43,773	44,834	46,979	47,982	50,892	57,167	59,703